TensorFlow

Plan

1. Wstęp
2. Tensory
    1. tf.Tensor
    2. Operacje na tensorach
    3. Szczególne rodzaje tensorów
    4. tf.Variable
3. Dodatki

Wstęp

TensorFlow

TensorFlow to stworzona w 2011 roku przez firmę Google biblioteka dedykowana do generowania oraz wdrażania modeli uczenia maszynowego. W 2015 roku kod biblioteki został przeniesiony do domeny publicznej na licencji Apache2.0 i jest utrzymywany na githubie pod adresem https://github.com/tensorflow/tensorflow. Biblioteka napisana jest w języku C++, posiada pełny wrapper w języku Python oraz częściowe wrappery w językach: Java, JavaScript, Go i Swift. W roku 2017 została wypuszczona pierwsza stabilna wersja biblioteki – TensorFlow 1.0. W 2019 roku Google wypuściła kolejną wersję biblioteki - TensorFlow 2.0. W nowa wersji położono szczególny nacisk na łatwość używania biblioteki oraz wyposażenie biblioteki w wysokopoziomowe api.

Dokumentacja biblioteki znajduje się pod adresem https://tensorflow.org.

Opanuj swoją ścieżkę

Aby zostać ekspertem w dziedzinie uczenia maszynowego, potrzebujesz najpierw solidnych podstaw w **czterech obszarach uczenia się** : kodowania, matematyki, teorii uczenia maszynowego i tworzenia własnego projektu uczenia maszynowego od początku do końca.

Rozpocznij od wyselekcjonowanych **programów nauczania** TensorFlow, aby poprawić te cztery umiejętności, lub wybierz własną ścieżkę nauki, przeglądając naszą **bibliotekę zasobów** poniżej.

Wprowadzenie do TensorFlow

https://www.tensorflow.org/learn

TensorFlow | Zainstaluj | Nauka | Interfejs API | Zasoby | Społeczność | Dlaczego TensorFlow | Wyniki wyszukiwania | Polski | GitHub | Zaloguj się

translated by Google Ta strona została przetłumaczona przez Cloud Translation API. Switch to English

Wprowadzenie do TensorFlow

TensorFlow ułatwia początkującym i ekspertom tworzenie modeli uczenia maszynowego dla komputerów stacjonarnych, urządzeń mobilnych, sieci i chmury. Aby rozpocząć, zapoznaj się z poniższymi sekcjami.

Przepływ Tensora

Poznaj podstawy TensorFlow dzięki samouczkom dla początkujących i ekspertów, które pomogą Ci stworzyć kolejny projekt uczenia maszynowego.

Dla JavaScript

Użyj TensorFlow.js do tworzenia nowych modeli uczenia maszynowego i wdrażania istniejących modeli za pomocą JavaScript.

Do urządzeń mobilnych i IoT

Uruchom wnioskowanie za pomocą TensorFlow Lite na urządzeniach mobilnych i wbudowanych

Do produkcji

Wdróż gotowy do produkcji potok ML do uczenia i wnioskowania przy użyciu Ten

Materiały edukacyjne

GitHub - tensorflow/tensorflow:

github.com/tensorflow/tensorflow

Product Team Enterprise Explore Marketplace Pricing Search / Sign in Sign up

tensorflow / tensorflow Public

Notifications Fork 86.9k Star 166k

Code Issues 2.1k Pull requests 235 Actions Projects 1 Security 319 Insights

master 62 branches 173 tags Go to file Code

sngyhan and tensorflower-gardener Support freezing for resource variables ... d97fdd3 9 hours ago 131,525 commits

.github	Assigns reviewers to Apple Silicon PRs.	15 days ago
tensorflow	Support freezing for resource variables	9 hours ago
third_party	Update TFRT dependency to use revision	16 hours ago
tools	Merge pull request #25673 from Ryan-Qiyu-Jiang:env_capture_script_m...	3 years ago
.bazelrc	Rollback of PR #55534	yesterday
.bazelversion	Switch back to using released bazel	2 months ago
.clang-format	[.clang-format] Init @ root	7 months ago
.gitignore	Ignore CoreML BUILD files which are generated by the configure script	2 years ago
.pylintrc	Add soft-link to pylintrc to project root	3 years ago
.zenodo.json	Add .zenodo.json for clean automated DOI numbers.	14 months ago
AUTHORS	Add Arm Ltd to AUTHORS	
BUILD	[NFC, internal change] Polish copybara workflow	

About

An Open Source Machine Learning Framework for Everyone

tensorflow.org

python machine-learning deep-neural-networks deep-learning neural-network tensorflow ml distributed

Readme

Apache-2.0 license

Code of conduct

Cite this repository

166k stars

7.8k watching

Kod biblioteki

TensorFlow 1.0 vs TensorFlow 2.0

Początkowo biblioteka TensorFlow zniechęcała użytkowników skomplikowanym schematem użycia. Prowadziło to do zwiększenia popularności młodszych, wyżej poziomowych bibliotek takich jak PyTorch czy Keras. Żeby zapobiec utracie użytkowników twórcy TensorFlow zdecydowali się zintegrować TensorFlow z mniejszą biblioteką Keras. Jednak nie zmieniło to znacząco popularności biblioteki. Pisanie kodu w TensorFlow wciąż było skomplikowane. PyTorch dzięki prostocie użycia w 2019 roku zaczęła popularnością dorównywać bibliotece TensorFlow.

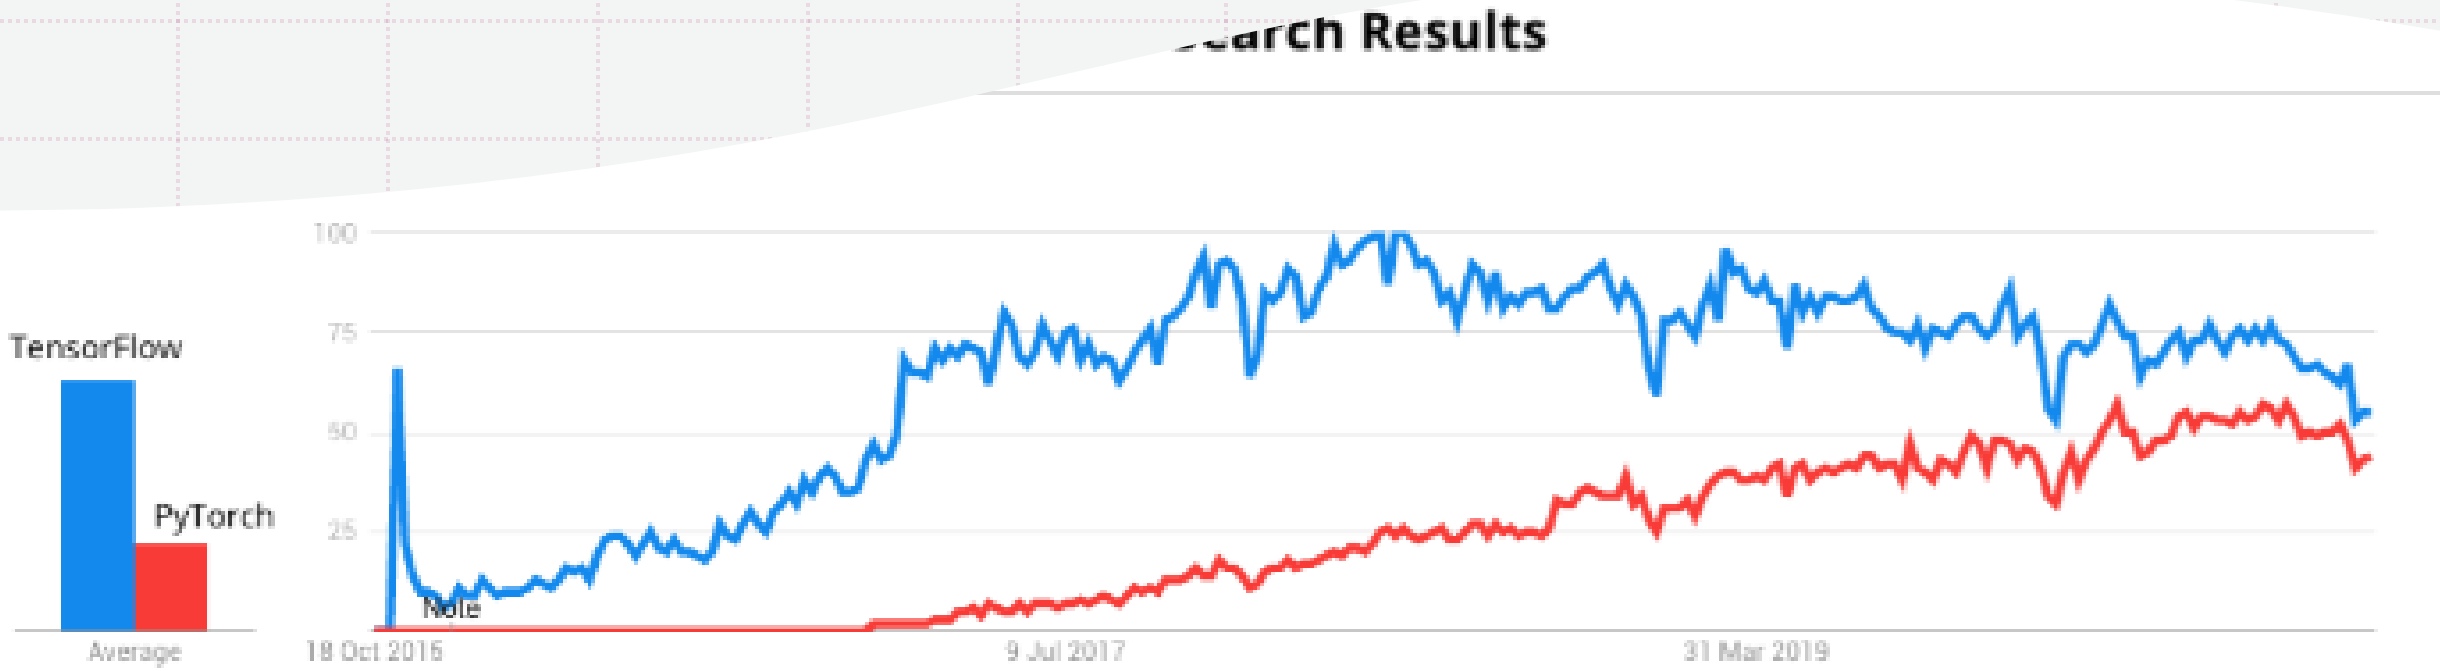

TensorFlow 1.0 vs TensorFlow 2.0

W związku z rosnącą popularnością PyTorch twórcy TensorFlow zdecydowali się na wprowadzenie zmian, które uprościły sposób korzystania z biblioteki. Do najważniejszych zmian towarzyszących nowszej wersji należą:

1. zrezygnowanie z mechanizmu sesji,
2. odejście od ręcznego tworzenia grafów obliczeniowych na rzecz "eager execution",
3. uspójnienie interfejsu programistycznego biblioteki,
4. wprowadzenie wysokopoziomego api na wzór biblioteki Keras.

Eager Execution vs graph execution and session

W wersji 1.x biblioteki Tensor instrukcje nie były wykonywane kolejno, tak jak w większości bibliotek. Instrukcje były tylko deklaracjami, a ich wykonanie oddelegowywane było do sesji. Po zainicjalizowaniu sesji biblioteka tworzyła z przekazanych do sesji, zadeklarowanych obiektów graf obliczeniowy i wszystkie obliczenia wykonywała na tym grafie (*graph execution*). Taki sposób pisania kodu jest trudniejszy od *eager execution* (wykonywanie kodu linijka po linijce), ale w zamian kod może być znacząco szybszy. Wynika to z faktu, że tworzone w sesji grafy są zoptymalizowane pod względem obliczeniowym. W wersji 2.x wciąż można używać *graph execution*, ale domyślnym sposobem wykonywania kodu jest *eager exection*.

Więcej o grap execution znaleźć można w dodatkach do tej prezentacji.

Session

vs

Eager execution

```
import tensorflow as tf

a = tf.constant(5)
b = tf.constant(4)
c = a + b

with tf.Session() as sess:
  print(sess.run(c))
```

```
9
```

```
import tensorflow as tf

a = tf.constant(5)
b = tf.constant(4)
c = a + b

print(c.numpy())
```

```
9
```

Zalety biblioteki TensorFlow

- zoptymalizowana pod kątem tworzenia i trenowania modeli uczenia maszynowego,
- jest open source
- posiada zbiór przydatnych narzędzi: **TensorBoard**, TensorFlow Playground, **TensorFlow Hub**,
- kompatybilna z popularnymi bibliotekami Pythona: NumPy, Matplotlib, pandas,
- posiada gotowe zbiory danych,
- posiada bogaty zbiór wytrenowanych modeli w TF Hub,
- posiada narzędzia do trenowania modeli na urządzeniach iOS, Android, Windows, MacOS, web
- posiada świetną dokumentację oraz wiele samouczków
- posiada ogromną, aktywną społeczność

TensorBoard | TensorFlow

https://www.tensorflow.org/tensorboard

TensorFlow Zainstaluj Nauka Interfejs API Zasoby Społeczność Dlaczego TensorFlow Wyniki wyszukiwania Polski GitHub Zaloguj się

TensorBoard

Informacje ogólne Przewodnik

translated by Google Ta strona została przetłumaczona przez Cloud Translation API. Switch to English

TensorBoard: zestaw narzędzi do wizualizacji TensorFlow

TensorBoard zapewnia wizualizację i narzędzia potrzebne do eksperymentowania z uczeniem maszynowym:

- Śledzenie i wizualizacja wskaźników, takich jak strata i dokładność
- Wizualizacja wykresu modelu (operacje i warstwy)
- Przeglądanie histogramów wag, błędów systematycznych lub innych tensorów zmieniających się w czasie
- Projekcja osadzeń do przestrzeni o niższych wymiarach
- Wyświetlanie obrazów, tekstu i danych dźwiękowych
- Profilowanie programów TensorFlow
- I wiele więcej

TensorBoard.dev umożliwia łatwe hostowanie, śledzenie i udostępnianie wyników eksperymentów.

Rozpocznij Zacznij korzystać z TensorBoard.dev

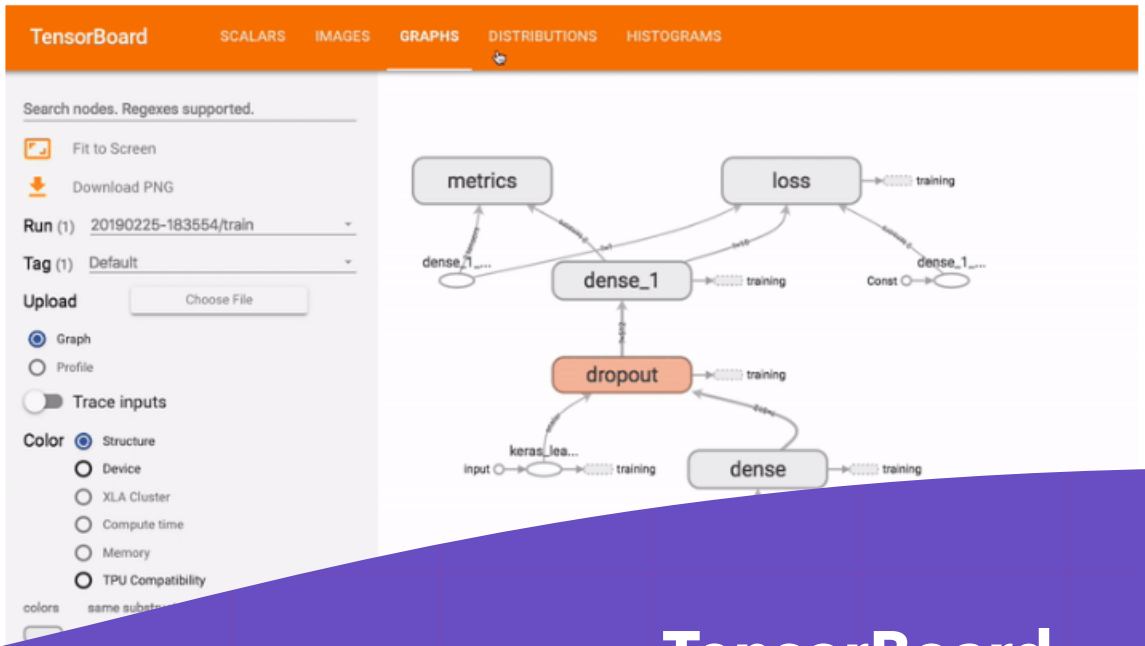

TensorBoard

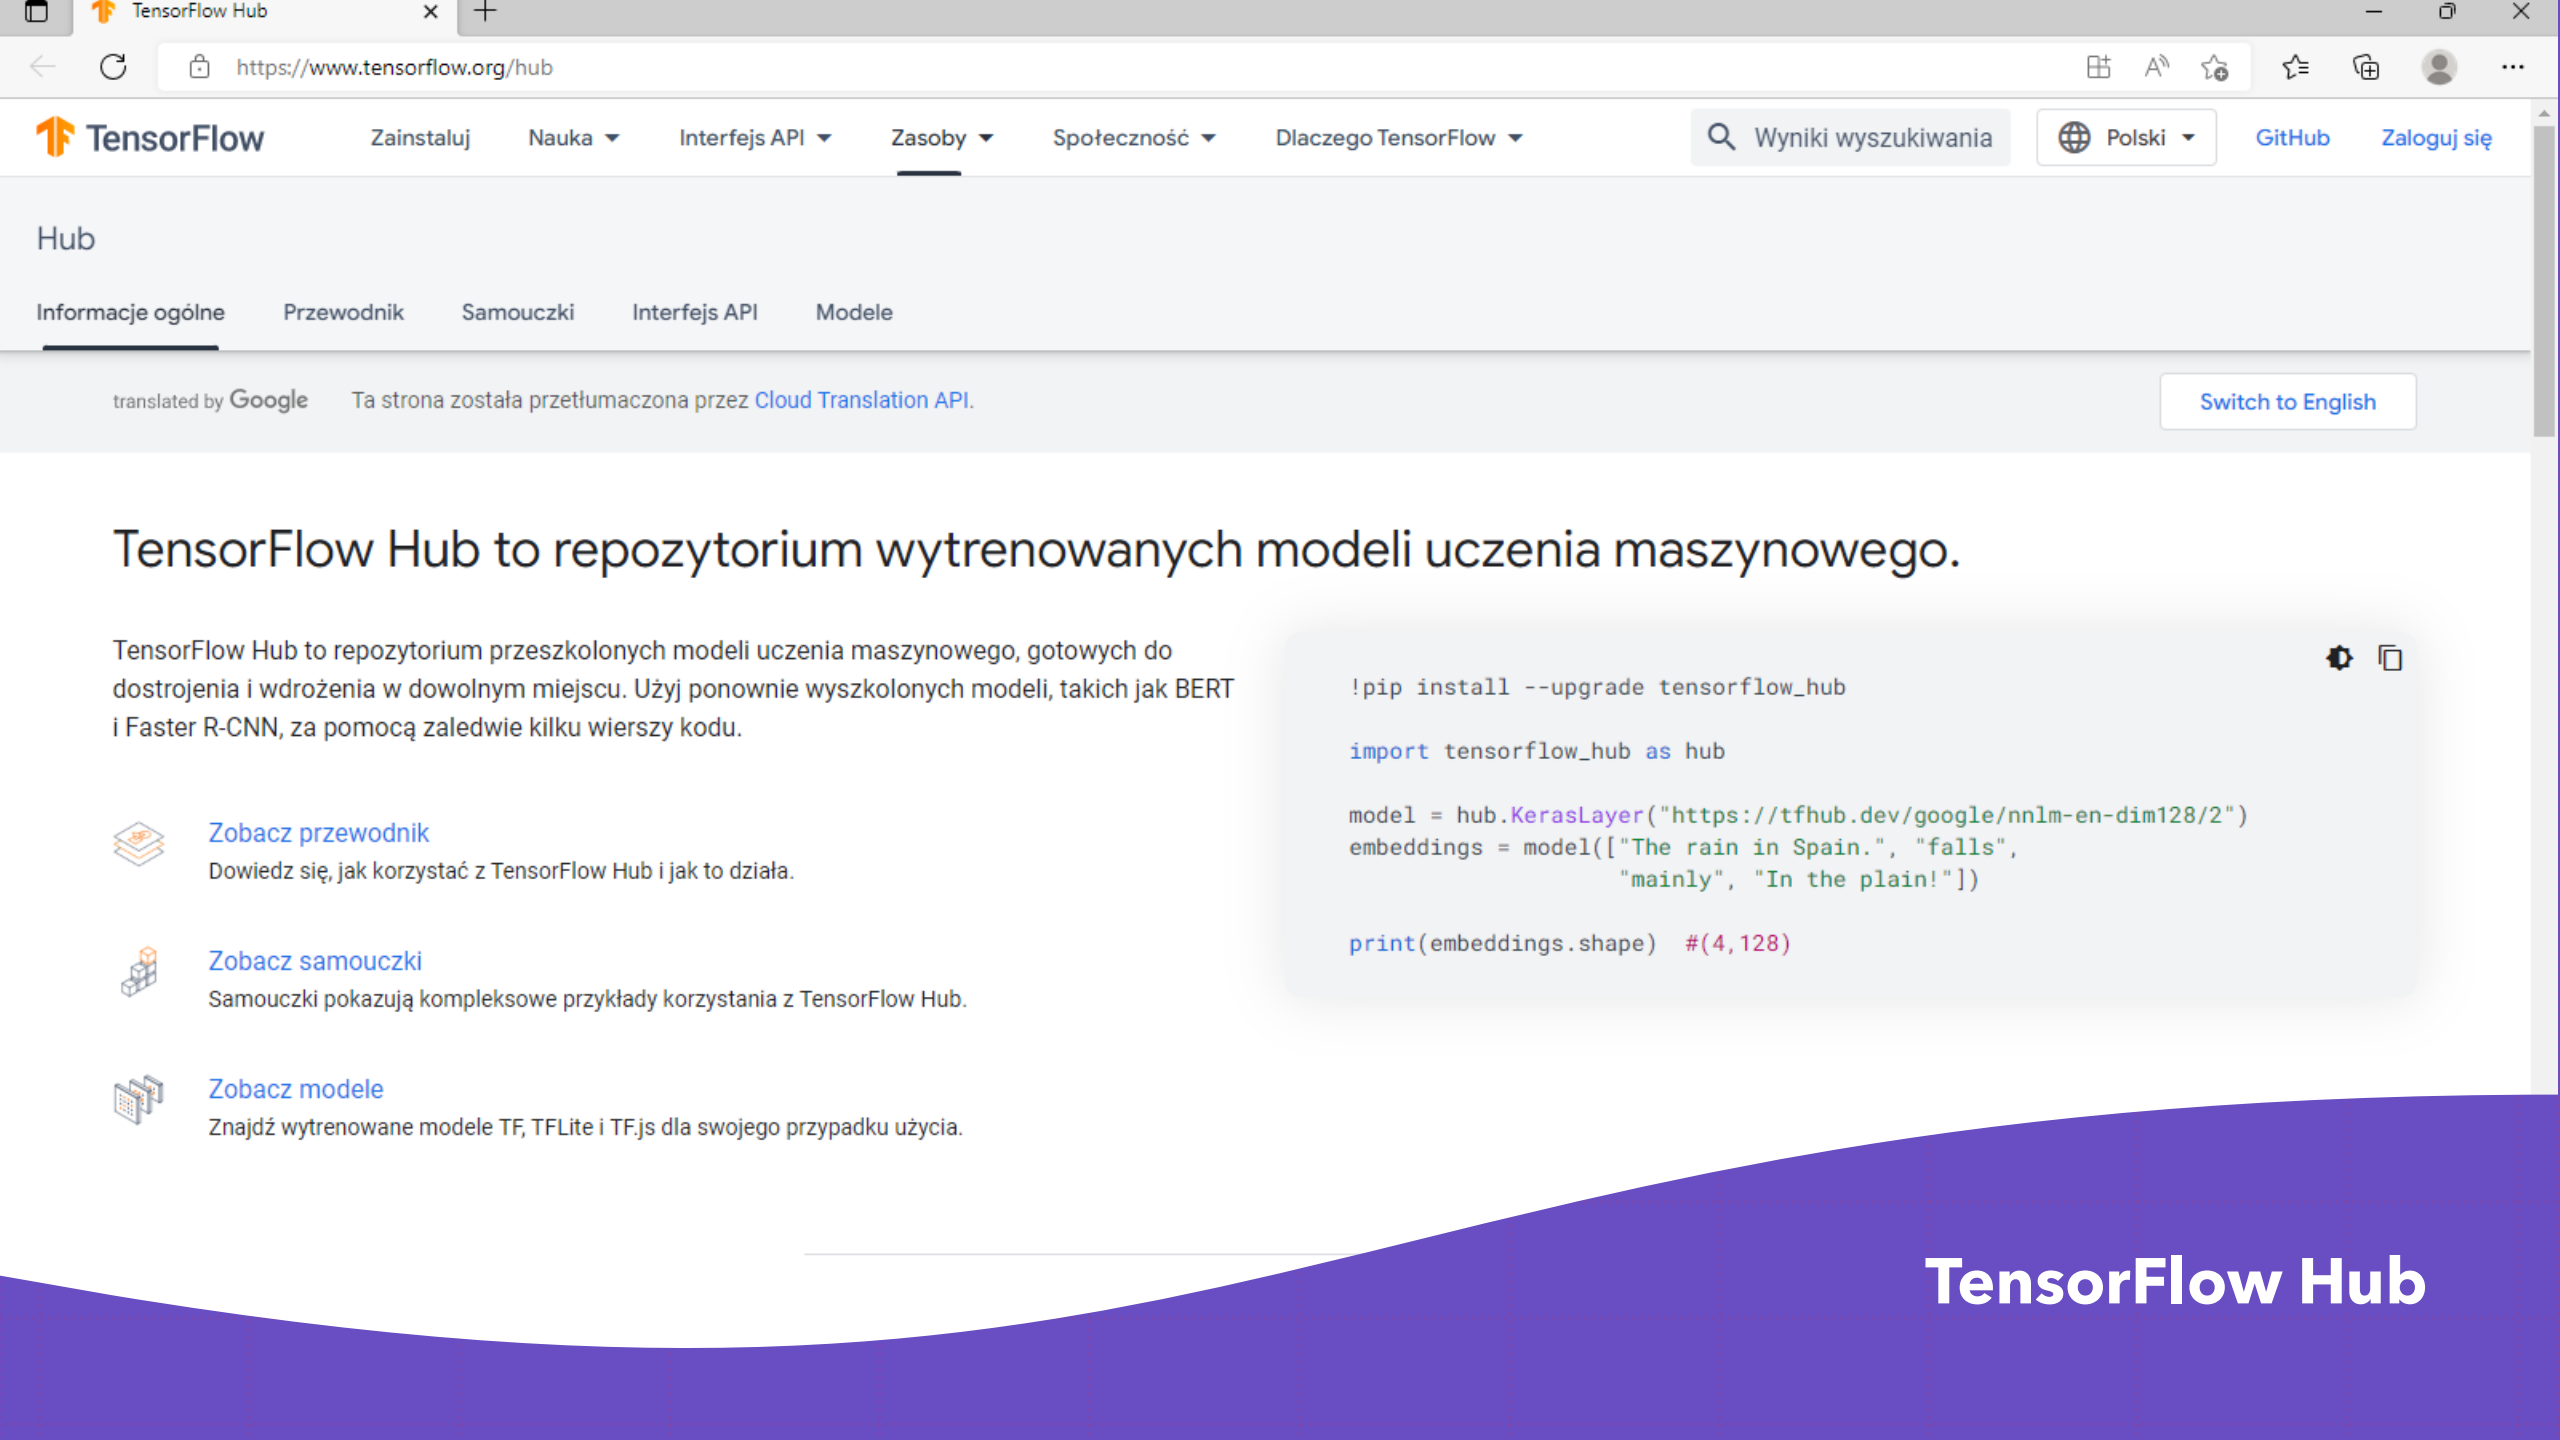

TensorFlow Hub

A Neural Network Playground

https://playground.tensorflow.org/#activation=tanh&batchSize=10&dataset=circle&regDataset=reg-plane&learningRate=0.03&regularizationRate=0&noise=0&networkShape=4,2&s...

Tinker With a **Neural Network** Right Here in Your Browser.
Don't Worry, You Can't Break It. We Promise.

Epoch
000,000

Learning rate: 0.03

Activation: Tanh

Regularization: None

Regularization rate: 0

Problem type: Classification

DATA

Which dataset do you want to use?

Ratio of training to test data: 50%

Noise: 0

Batch size: 10

REGENERATE

FEATURES

Which properties do you want to feed in?

X_1

X_2

X_1^2

X_2^2

X_1X_2

$\sin(X_1)$

2 HIDDEN LAYERS

4 neurons

2 neurons

*This is the output from one **neuron**. Hover to see it larger.*

*The outputs are mixed with varying **weights**, shown by the thickness of the lines.*

OUTPUT

Test loss 0.517

Training loss 0.498

TensorFlow Playground

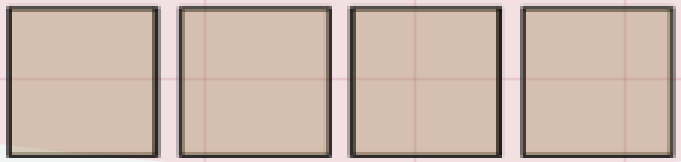

RANK-1 TENSOR

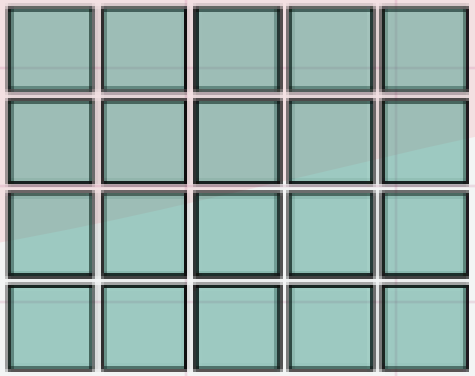

RANK-2 TENSOR

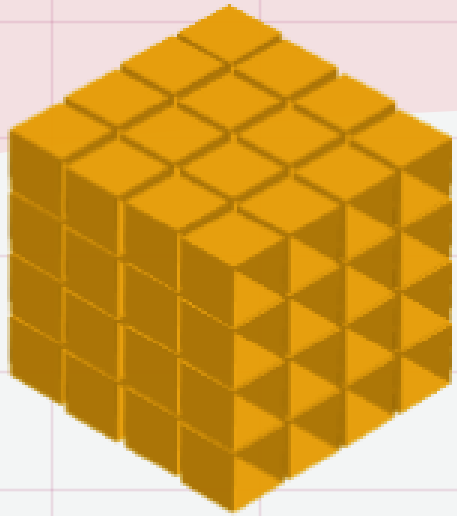

RANK-3 TENSOR

Tensory

Tensor - definicja

W zależności od dziedziny słowo tensor może znaczyć coś innego. Spośród podstawowych definicji słowa tensor wyróżnić można definicję:

- **matematyczną**

Obiekt matematyczny, którego współrzędne zmieniaja się w określony sposób przy transformacji układu współrzędnych (tzw. bazy). Na przykład: tensor metryczny.

- **fizyczną**

Obiekt fizyczny, który posiada określone niezmienniki przy afinicznej transformacji układu odniesienia. Na przykład: tensor naprężeń.

- **programistyczną**

Uogólnienie tablicy, na którym wybrane operacje (iloczyny) wykonywane są w specyficzny sposób. W bibliotece tensorflow tensor reprezentowany jest za pomocą klasy ***tf.Tensor*** *(tensor niemodyfikowalny) oraz* ***tf.Variable*** *(tensor modyfikowalny).*

tf.Tensor

tf.Tensor - tworzenie

Z perspektywy programisty tensory są bardzo podobne do tablic numpy. W bibliotece tensorflow tensory reprezentowane są za pomocą klas tf.Tensor oraz tf.Variable. W pierwszej kolejności popatrzmy na klasę **tf.Tensor**. W bibliotece tensorflow istnieje kilka funkcji do tworzenia obiektów tej klasy.

constant()	**ones_like()**	**zeros_like()**	**fill()**
ones()	**zeros()**	**range()**	**random.normal()**

Tworzenie obiektów klasy tf.Tensor poprzez ich bezpośrednią inicjalizację nie jest zalecane przez twórców tensorflow. Obiekty klasy tf.Tensor są **niemodyfikowalne** (niemutowalne), tzn. po utworzeniu nie można zmieniać ich wartości (jak napisy i krotki w pythonie).

tf.Tensor – charakterystyki

Do podstawowych charakterystyk tensora należą:

1. rząd (*ang. rank*) - liczba wymiarów tensora (skalar jest tensorem rzędu 0, wektor jest tensorem rzędu 1, macierz jest tensorem rzędu 2)

2. kształt (*ang. shape*) - lista zawierająca długość (liczbę elementów) każdego z wymiarów tensora.

3. rozmiar (*ang. size*) - całkowita liczba elementów tensora

4. typ (*ang. type*) - wszystkie elementy tensora muszą być jednakowego typu.

Poszczególne charakterystyki zostaną szczegółowo omówione na kolejnych slajdach.

tf.Tensor – rząd

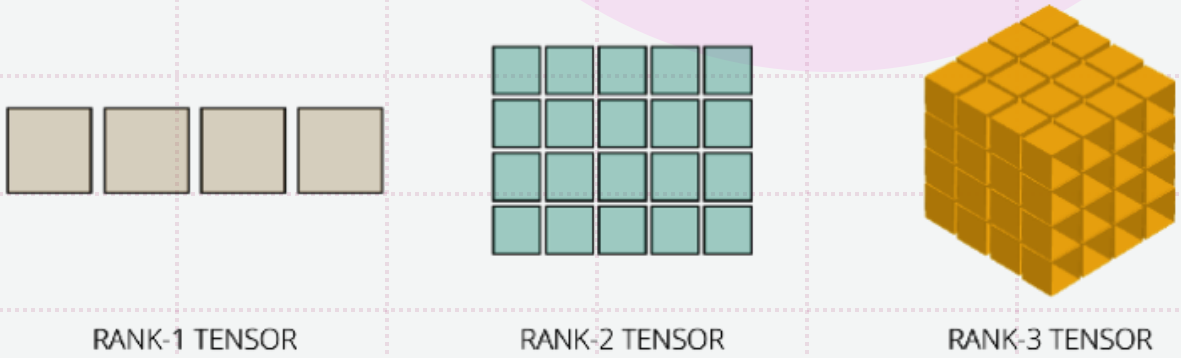

Tensory są klasyfikowane na podstawie liczby posiadanych wymiarów:

- tensor rzędu 0 to tensor posiadający jedną wartość i żadnych osi (skalar)
- tensor rzędu 1 to tensor posiadający listę wartości wzdłuż jednej osi (wektor)
- tensor rzędu 2 to tensor posiadający dwie osie (macierz)
- tensor rzędu N to tensor posiadający N osi

Rząd tensora przechowywany jest w atrybucie ***ndim***.

tf.Tensor - kształt

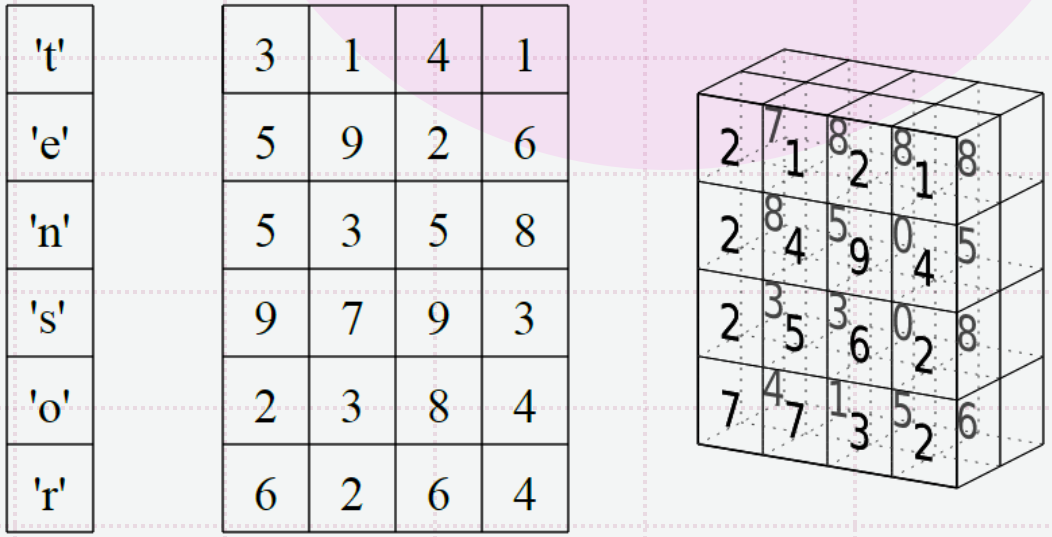

Zgodnie z konwencją przyjętą w tensorflow:

- dla tensora rzędu 2 pierwszy indeks atrybutu shape dotyczy liczby wierszy, a drugi liczby kolumn

- jeżeli tensor trzeciego rzędu wyobrazimy sobie jako pudełko, to pierwszy indeks atrybutu shape będzie dotyczył wysokości pudełka (liczby wierszy), drugi indeks długości pudełka (liczby kolumn), a trzeci indeks głębokości pudełka

Kształt tensora przechowywany jest w atrybucie ***shape***.

tf.Tensor - rozmiar

Rozmiar tensora to liczba jego elementów. W celu sprawdzenia rozmiaru tensora należy użyć funkcji ***tf.size().***

tf.Tensor - typ

Tensory poza standardowymi typami numerycznymi takim jak int czy float, mogą składać się również z elementów typu liczby zespolone czy napisy. Wszystkie elementy tensora muszą mieć ten sam typ.

Typ elementów tensora przechowywany jest w atrybucie dtype.

tf.Tensor - typ

Typ	Obiekt tensorflow
floating point	tf.float32, tf.float64
integer	tf.int8, tf.int16, tf.int32, tf.int64
unsigned integer	tf.uint8, tf.uint16
string	tf.string
boolean	tf.bool
complex number	tf.complex64, tf.complex128

Dostępne w tensorflow typy

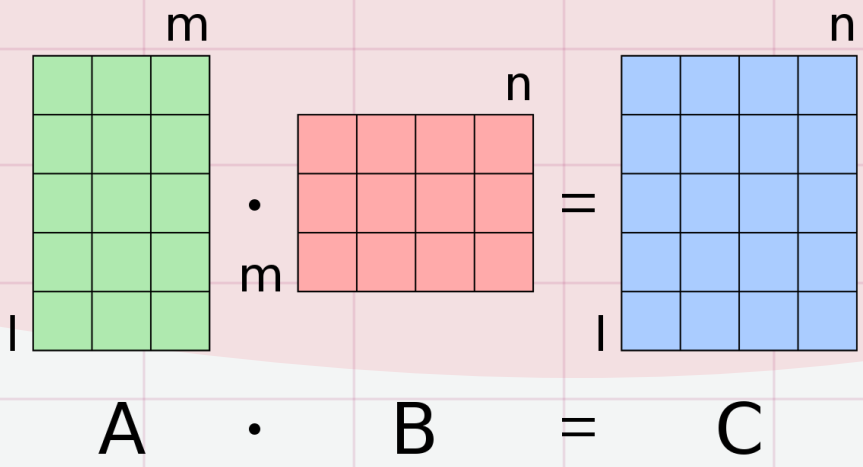

| + | - | * | / |@|%|

Podstawowe operacje wykonywane na tensorach

Podstawowe operacje na tensorach

Do podstawowych operacji można zaliczyć:

1. Indeksowanie
2. Operacje "po współrzędnych" (element-wise operations):
    A. Dodawanie (funkcja *tf.add*, operator "+")
    B. Odejmowanie (funkcja *tf.subtract*, operator "-")
    C. Mnożenie po współrzędnych (funkcja *tf.multiply*, operator "*")
    D. Dzielenie (funkcja tf.divide, operator "/")
    E. Modulo (funkcja *tf.math.floormod*, operator "%")
3. Mnożenie macierzowe (funkcja *tf.matmul, operator "@"*)
4. Znajdowanie maksimum, minimum oraz sumy wszystkich elementów (funckje *tf.reduce_max*, *tf.reduce_min*, *tf.reduce_sum*)
5. Znajdowanie indeksu maksymalnego, minimalnego elementu (funkcje *tf.argmax, tf.argmin*)

Indeksowanie

Do podstawowych reguł indeksowania należą:

- indeksowanie od 0
- obsługa ujemnych indeksów
- obsługa wycinków (operator ":")
- obsługa zagnieżdżonych indeksów (operator ",")

Zaawansowane operacje

Do zaawansowanych operacji można zaliczyć m.in.:

1. Zmiana kształtu tensora (funkcja *tf.reshape*)
2. Broadcasting
3. Liczenie gradientu (funkcja *tf.gradient*)

Broadcasting

Podobnie jak w bibliotece numpy, kiedy kształty tensorów nie są zgodne pod kątem wykonania danej operacji tensorflow na ile to jest możliwe powiela wartości w taki sposób, żeby dopasować do siebie wymiary obu tensorów.

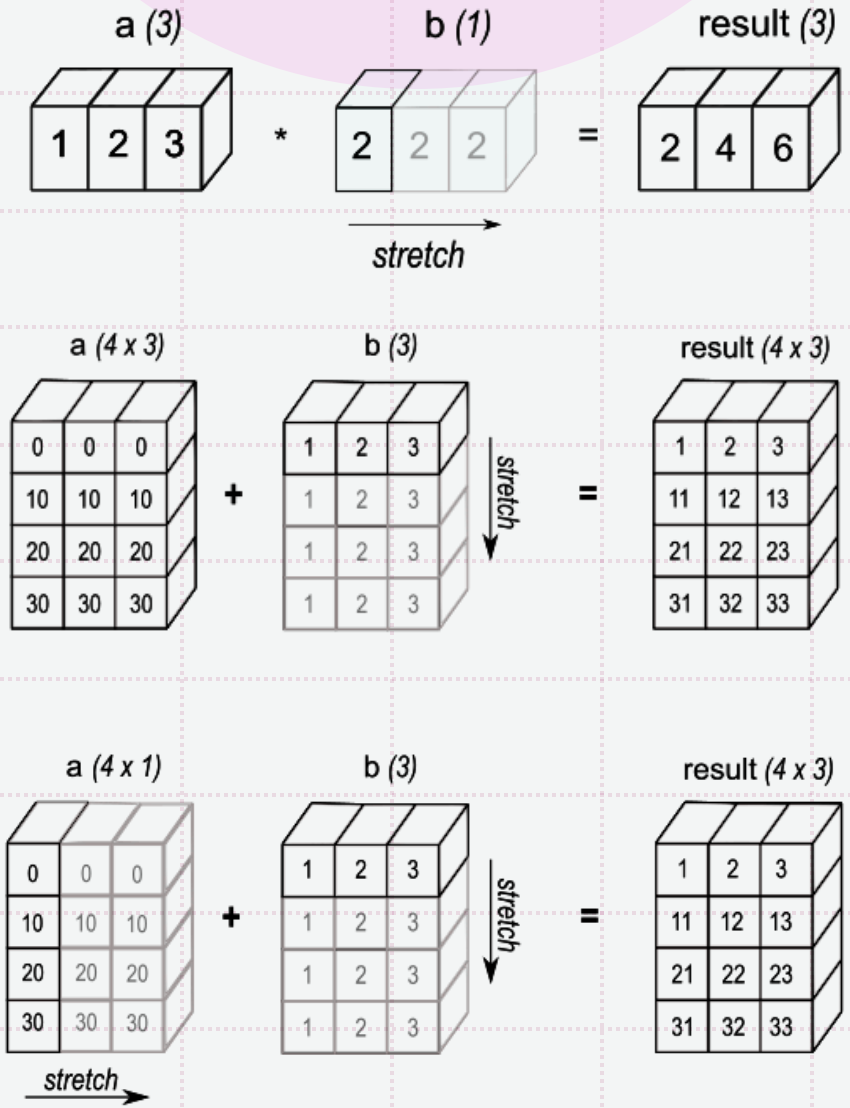

RAGGED TENSOR

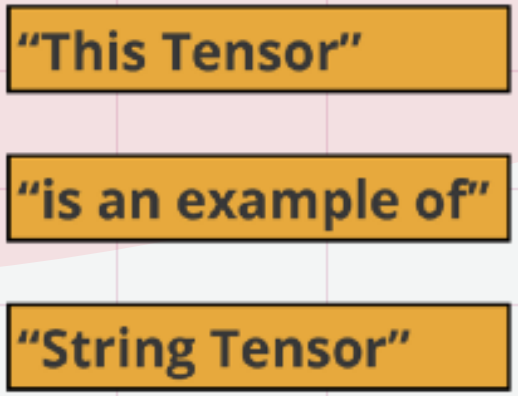

STRING TENSOR

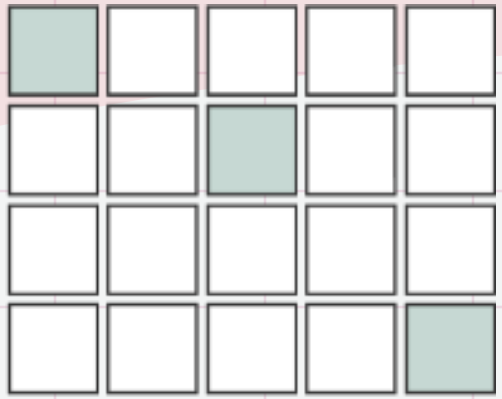

SPARSE TENSOR

Szczególne rodzaje tensorów

Szczególne tensory

Do szczególnych rodzajów tensorów można zaliczyć:

1. nierówny tensor (ragged tensor) - tensor z różną liczbą elementów wzdłuż jednej osi
2. tensor napisów - tensor składając się z elementami typu string
3. rzadki tensor (sparse tensor) - tensor z wieloma zerowymi elementami

tf.Variable

tf.Variable

Klasa tf.Variable podobnie jak klasa tf.Tensor reprezentuje tensor w bibliotece tensorflow. Obiekty klasy tf.Variable w odróżnieniu od obiektów klasy tf.Tensor są **modyfikowalne** (analogicznie jak listy i słowniki w pythonie). Ma to znaczenie w trakcie trenowania modelu, kiedy wagi modelu są nieustannie modyfikowane. Wagi przechowujemy w obiektach klasy tf.Variable.

Klasa tf.Variables jest podklasą klasy tf.Tensor w związku z tym dziedziczy wszystkie atrybuty i umiejętności klasy tf.Tensor.

Obiekty klasy tf.Variable modyfikujemy za pomocą funkcji assign().

tf.Variable - tworzenie

Obiekt klasy tf.Variable tworzymy standardowo, za pomocą inicjalizatora klasy. Parametrem inicjalizatora może być integer, float, string, lista, a nawet obiekt klasy tf.Tensor.

tf.Variable – charakterystyki i operacje

Wszystkie poznane atrybuty i metody klasy tf.Tensor oraz funkcje działające na obiektach tej klasy zachowują się w identyczny sposób na obiektach klasy tf.Variable.

Klasa tf.Variable posiada dodatkowo metodę ***assign()***. Metody *assign()* używamy do przypisania nowej wartości obiektowi klasy tf.Variable. Klasa tf.Variable nie obsługuje operatora przypisania.

Moduły TensorFlow

`audio` module: Public API for tf.audio namespace.

`autograph` module: Conversion of plain Python into TensorFlow graph code.

`bitwise` module: Operations for manipulating the binary representations of integers.

`compat` module: Functions for Python 2 vs. 3 compatibility.

`config` module: Public API for tf.config namespace.

`contrib` module: Contrib module containing volatile or experimental code.

`data` module: `tf.data.Dataset` API for input pipelines.

`debugging` module: Public API for tf.debugging namespace.

`distribute` module: Library for running a computation across multiple devices.

`distributions` module: Core module for TensorFlow distribution objects and helpers.

`dtypes` module: Public API for tf.dtypes namespace.

`errors` module: Exception types for TensorFlow errors.

`estimator` module: Estimator: High level tools for working with models.

`experimental` module: Public API for tf.experimental namespace.

`feature_column` module: Public API for tf.feature_column namespace.

`gfile` module: Import router for file_io.

`graph_util` module: Helpers to manipulate a tensor graph in python.

`image` module: Image processing and decoding ops.

`initializers` module: Public API for tf.initializers namespace.

`io` module: Public API for tf.io namespace.

`keras` module: Implementation of the Keras API meant to be a high-level API for TensorFlow.

`layers` module: Public API for tf.layers namespace.

`linalg` module: Operations for linear algebra.

`lite` module: Public API for tf.lite namespace.

`logging` module: Loggin

Moduły

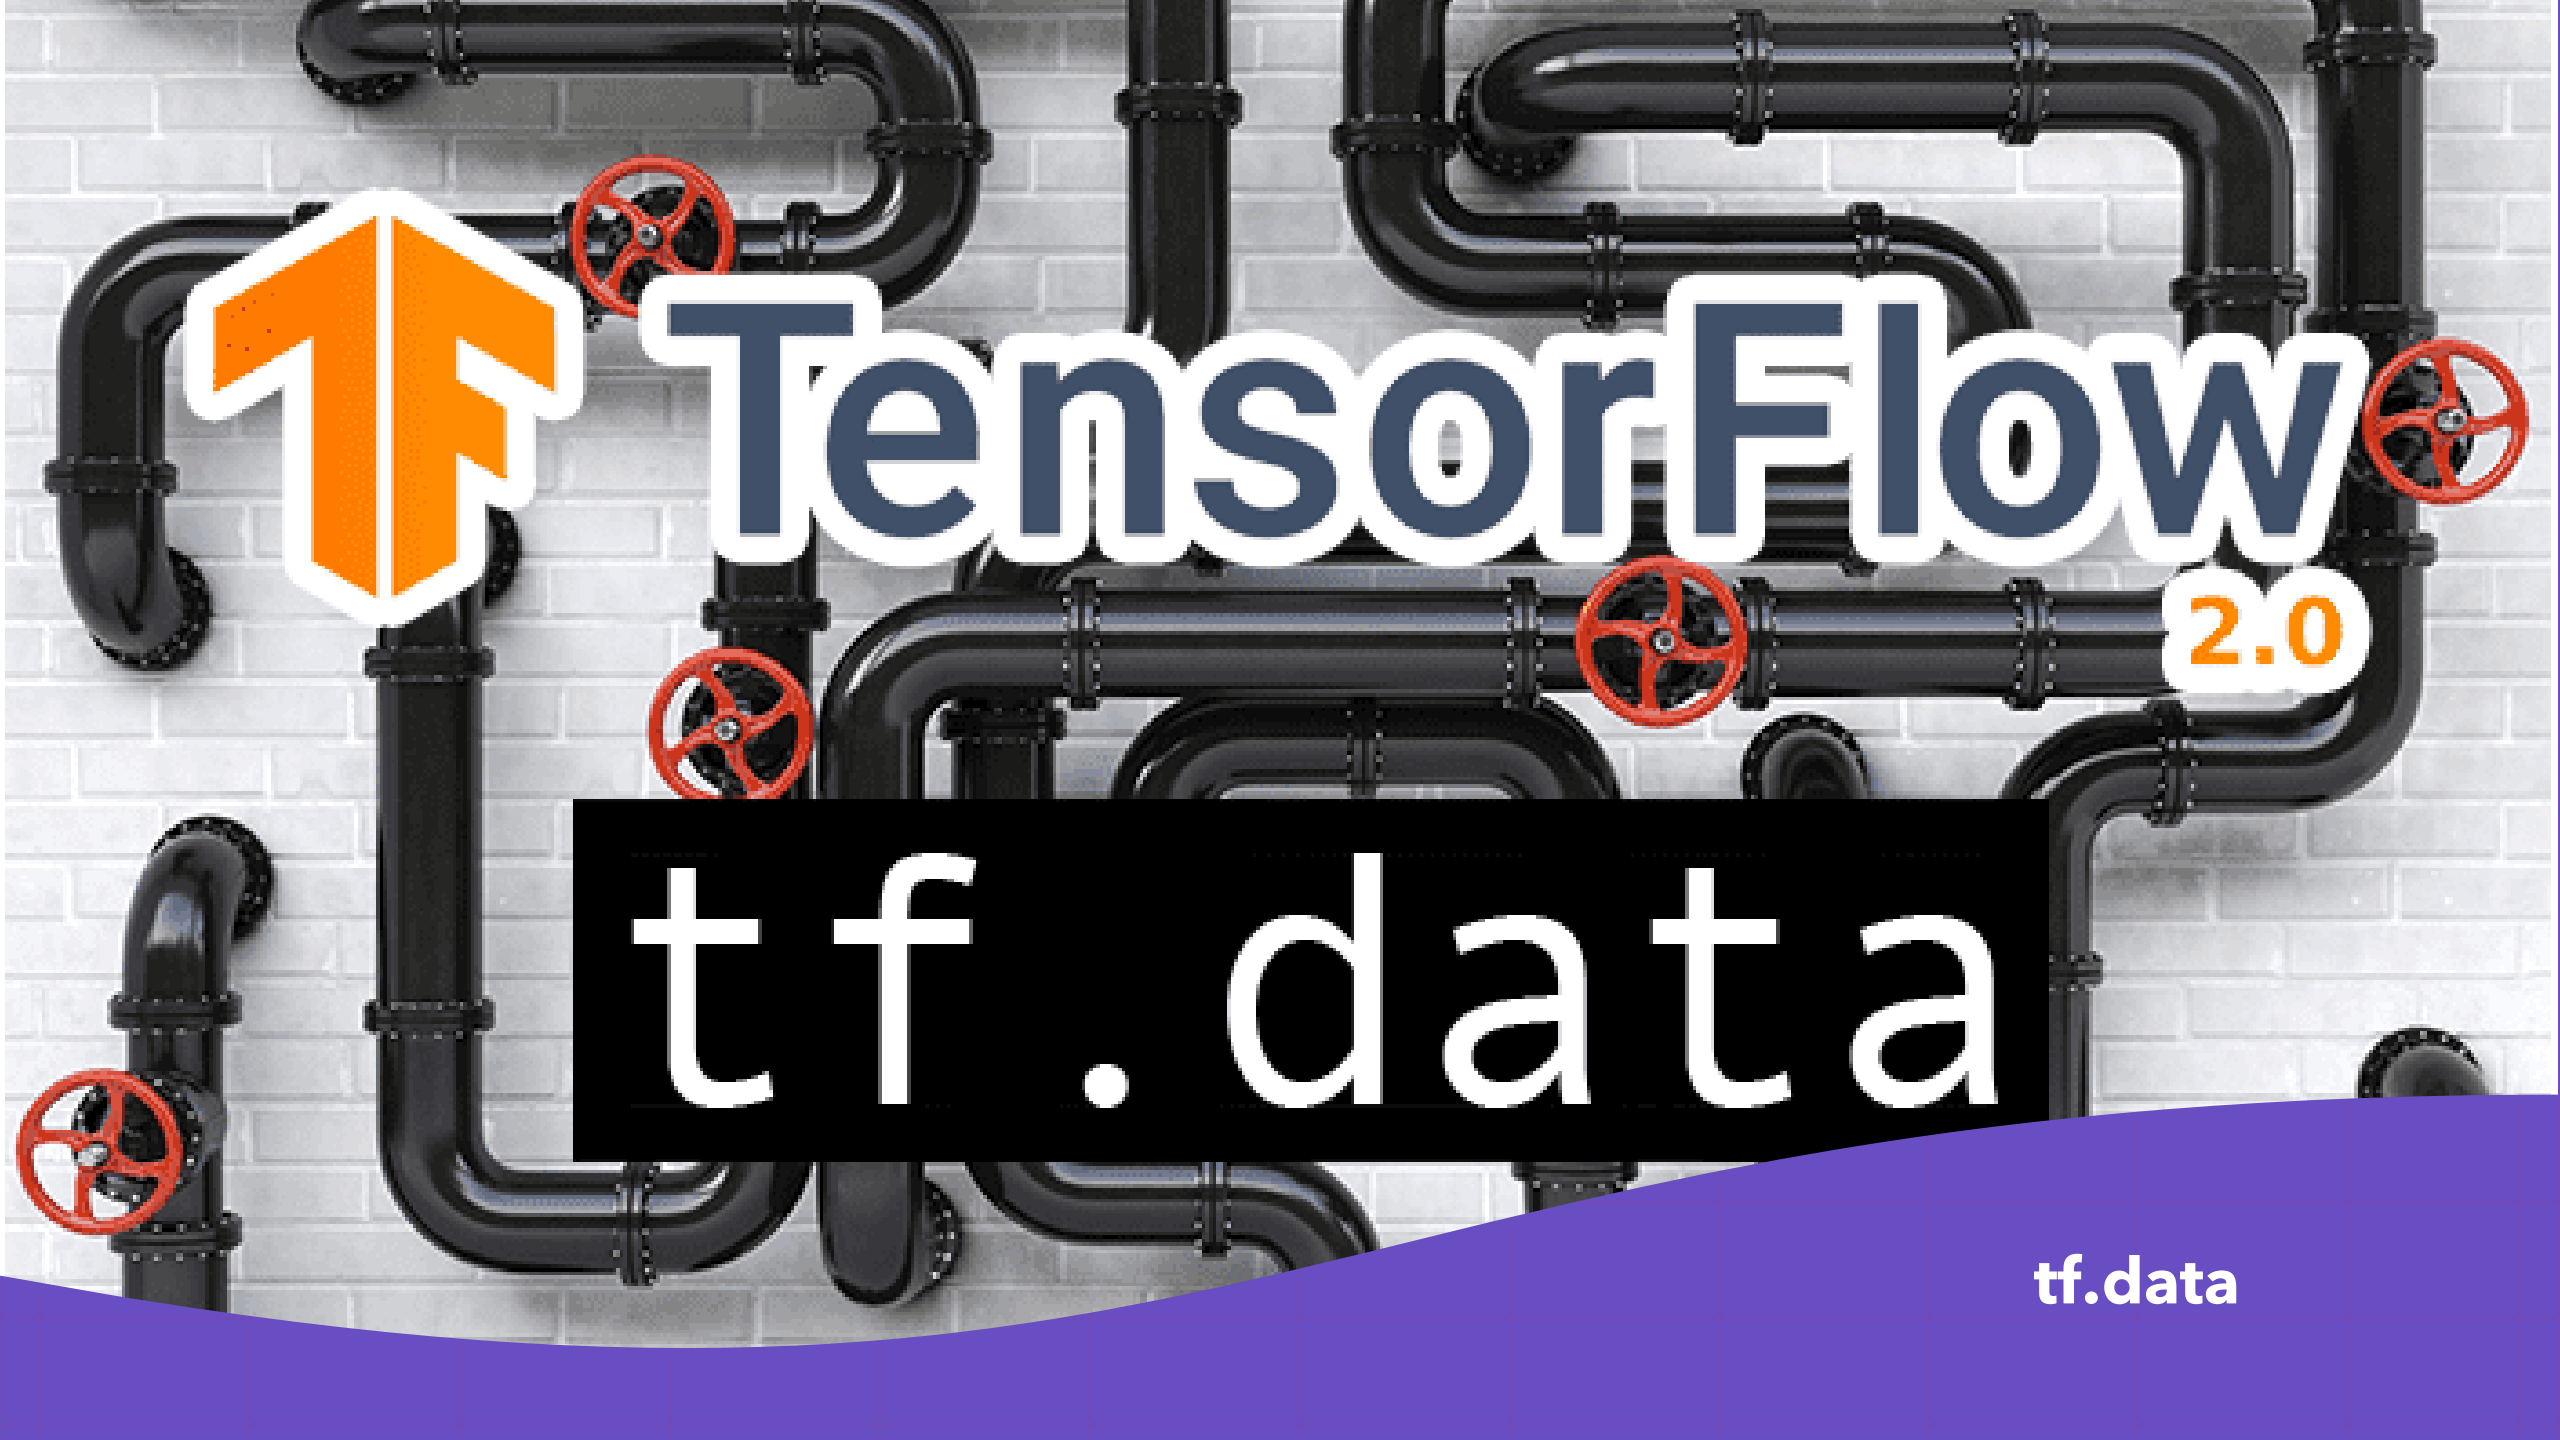
TensorFlow
2.0
tf.data

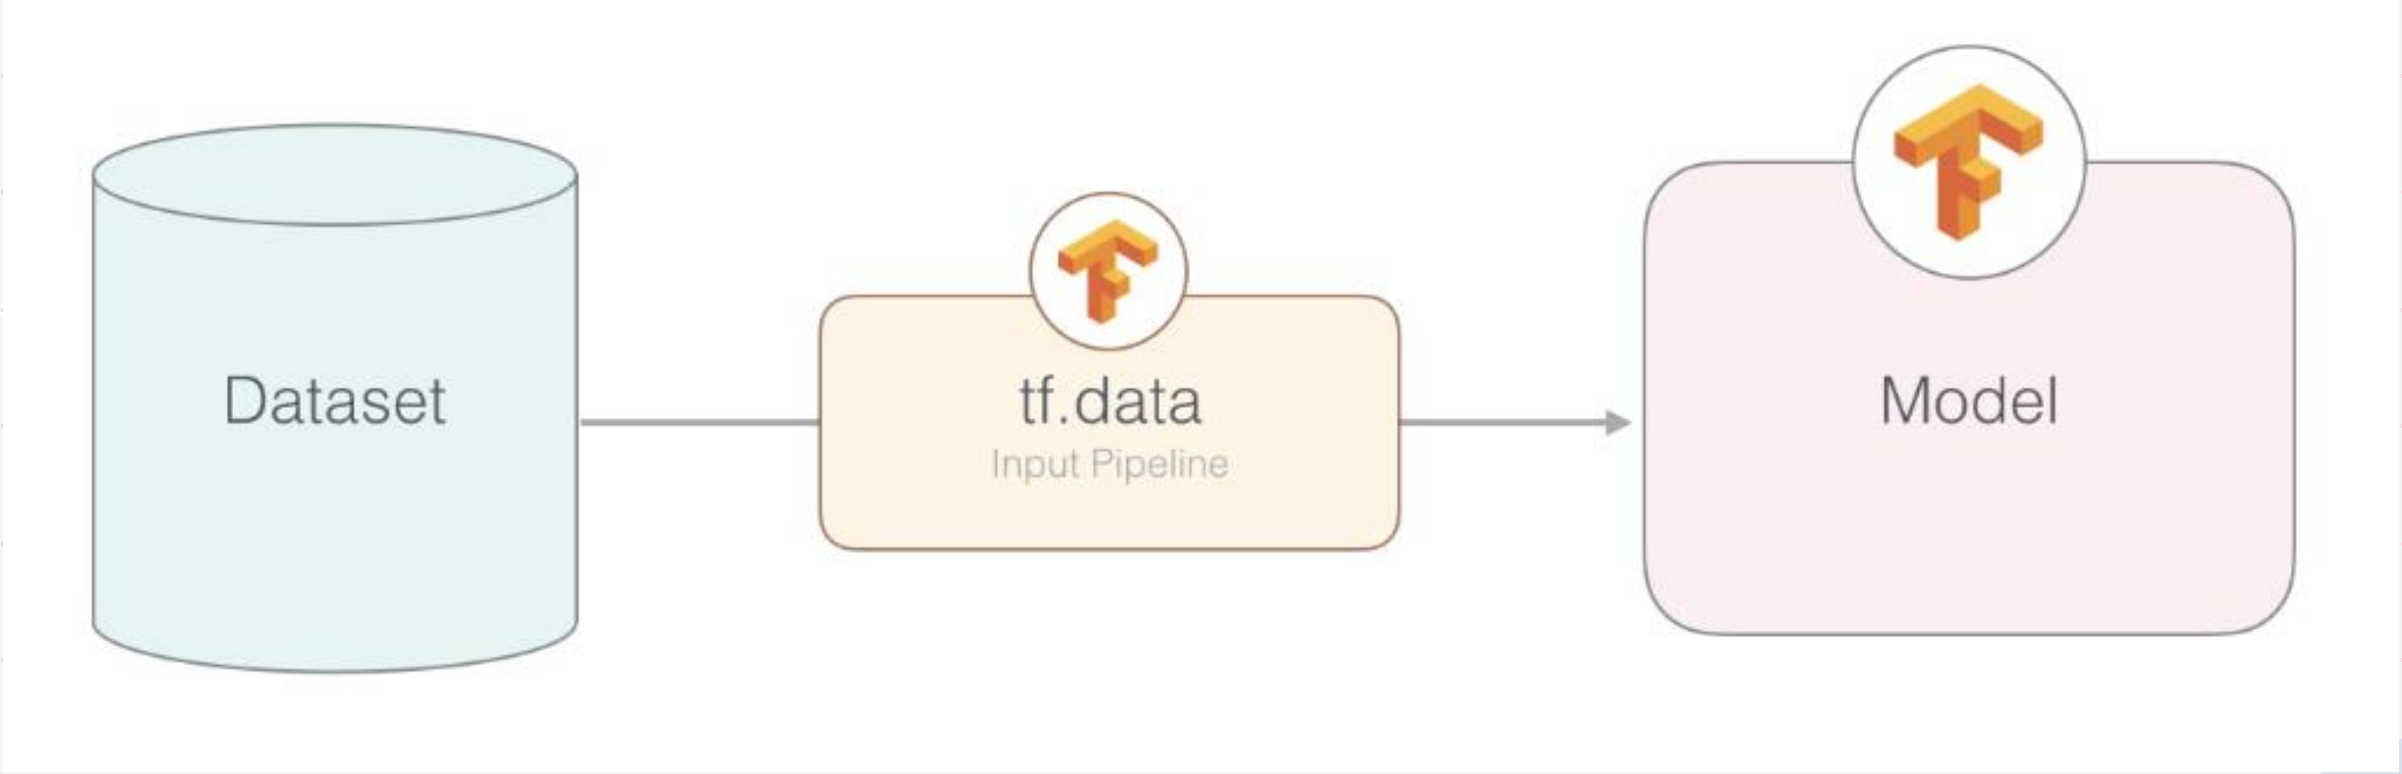
Dataset
tf.data
Input Pipeline
Model

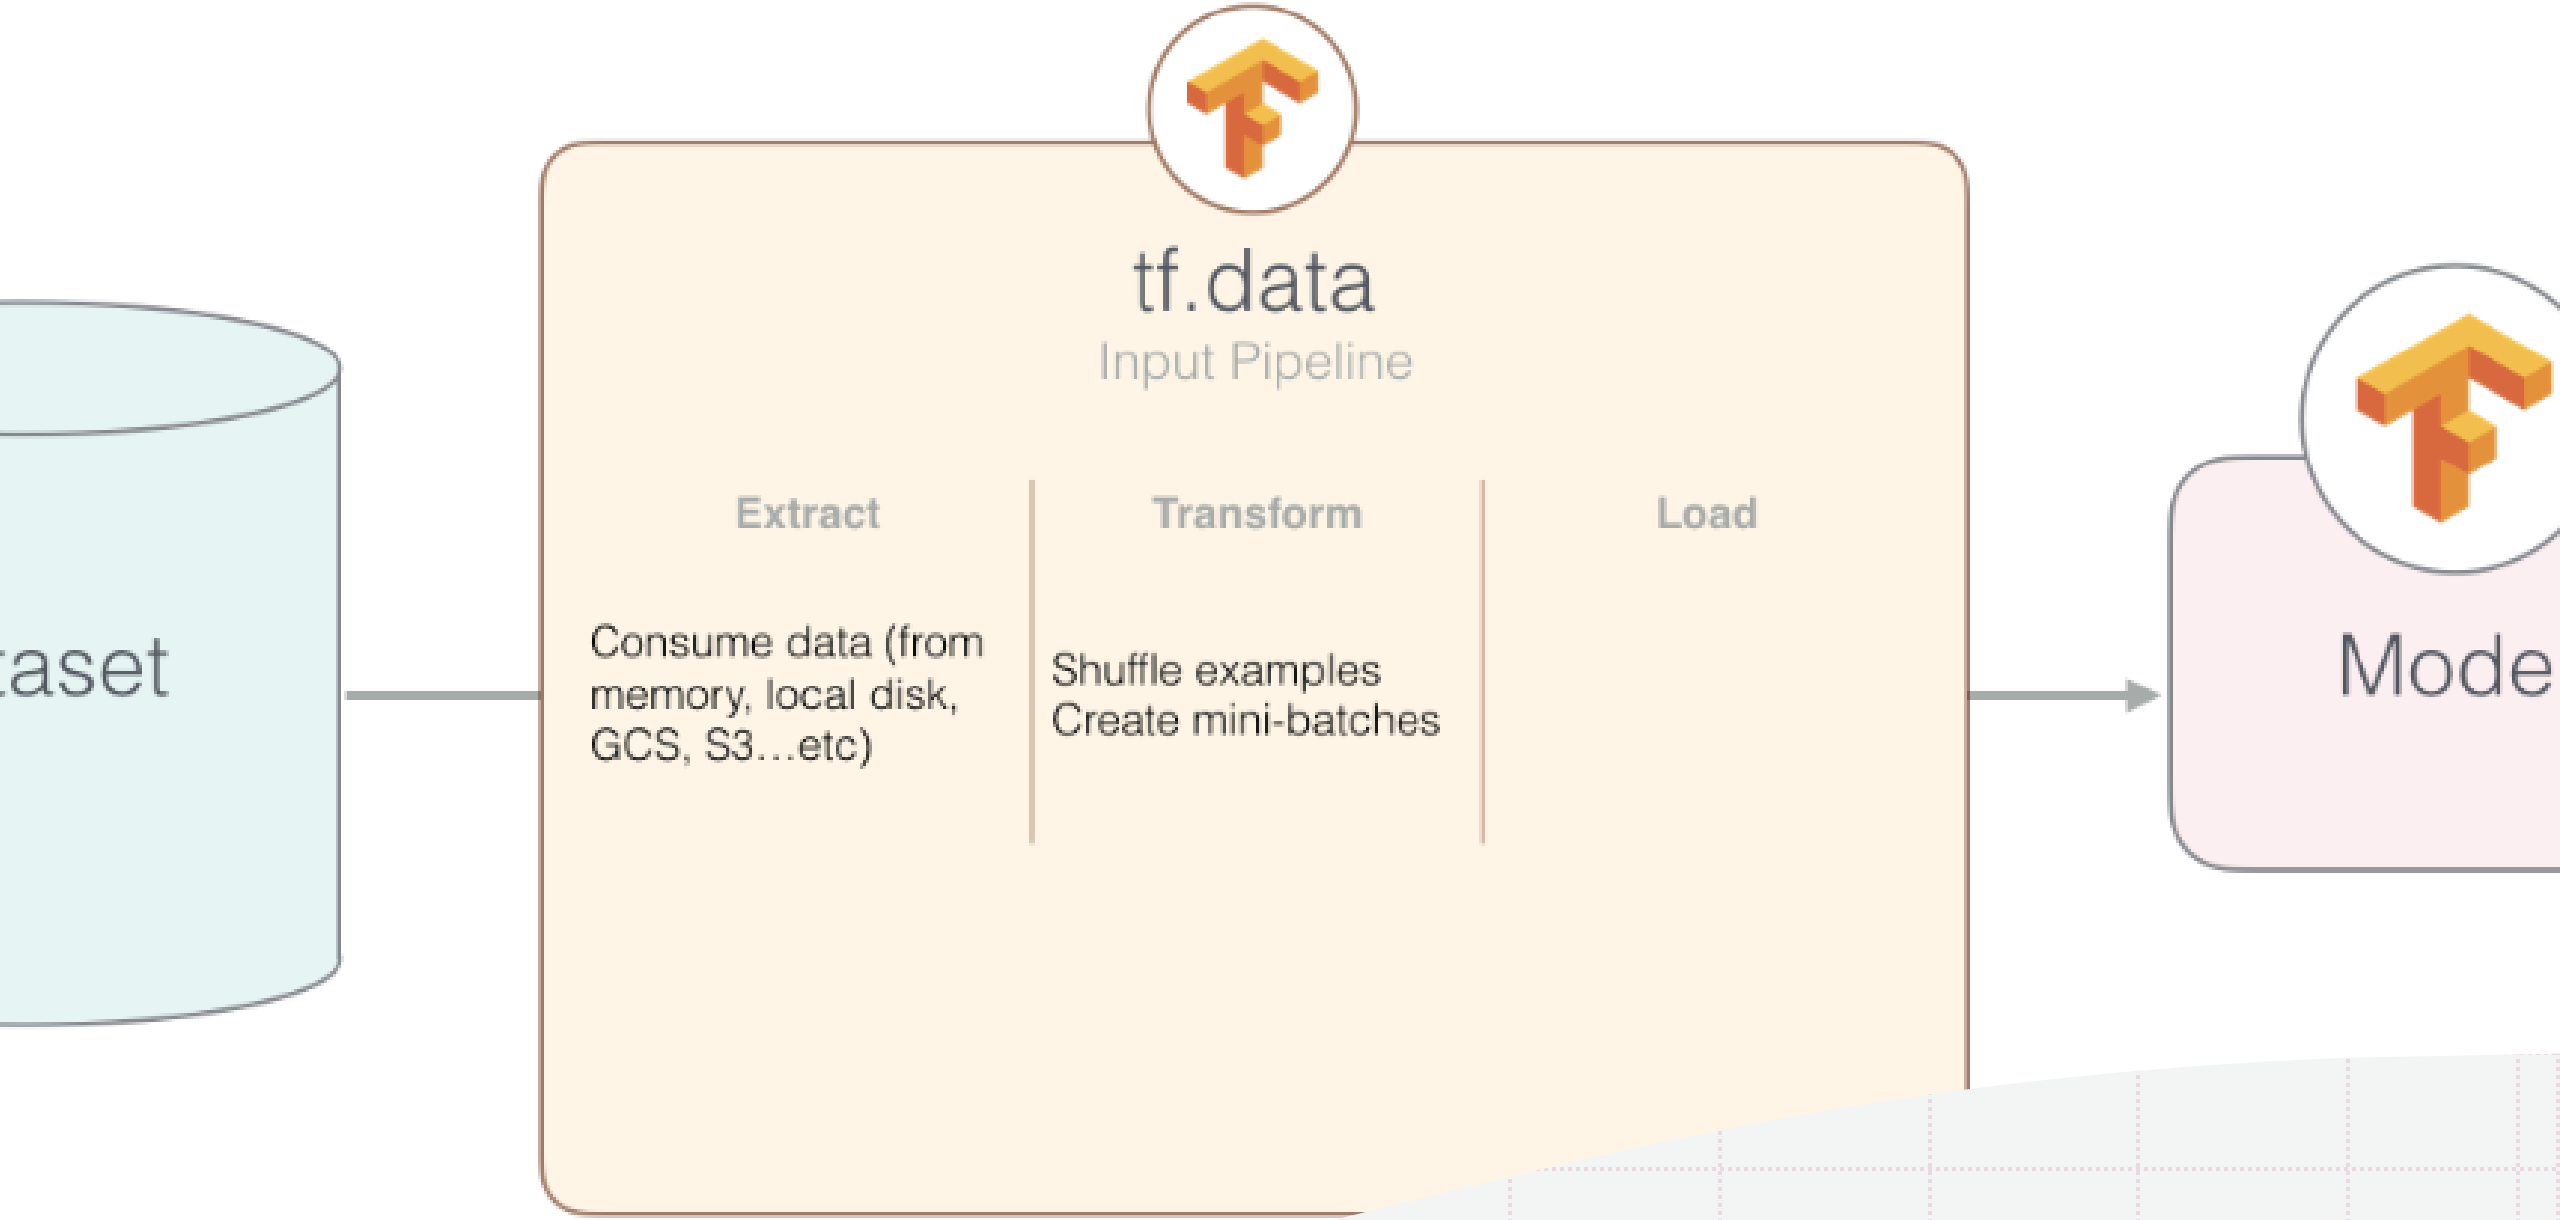

ETL – Extract Transform Load

E

```
files = tf.data.Dataset.list_files(file_pattern)
dataset = tf.data.TFRecordDataset(files)
```

T

```
dataset = dataset.shuffle(10000)
dataset = dataset.repeat(NUM_EPOCHS)
dataset = dataset.map(lambda x: tf.parse_single_example(x, features))
dataset = dataset.batch(BATCH_SIZE)
```

L

```
iterator = dataset.make_one_shot_iterator()
features = iterator.get_next()
```

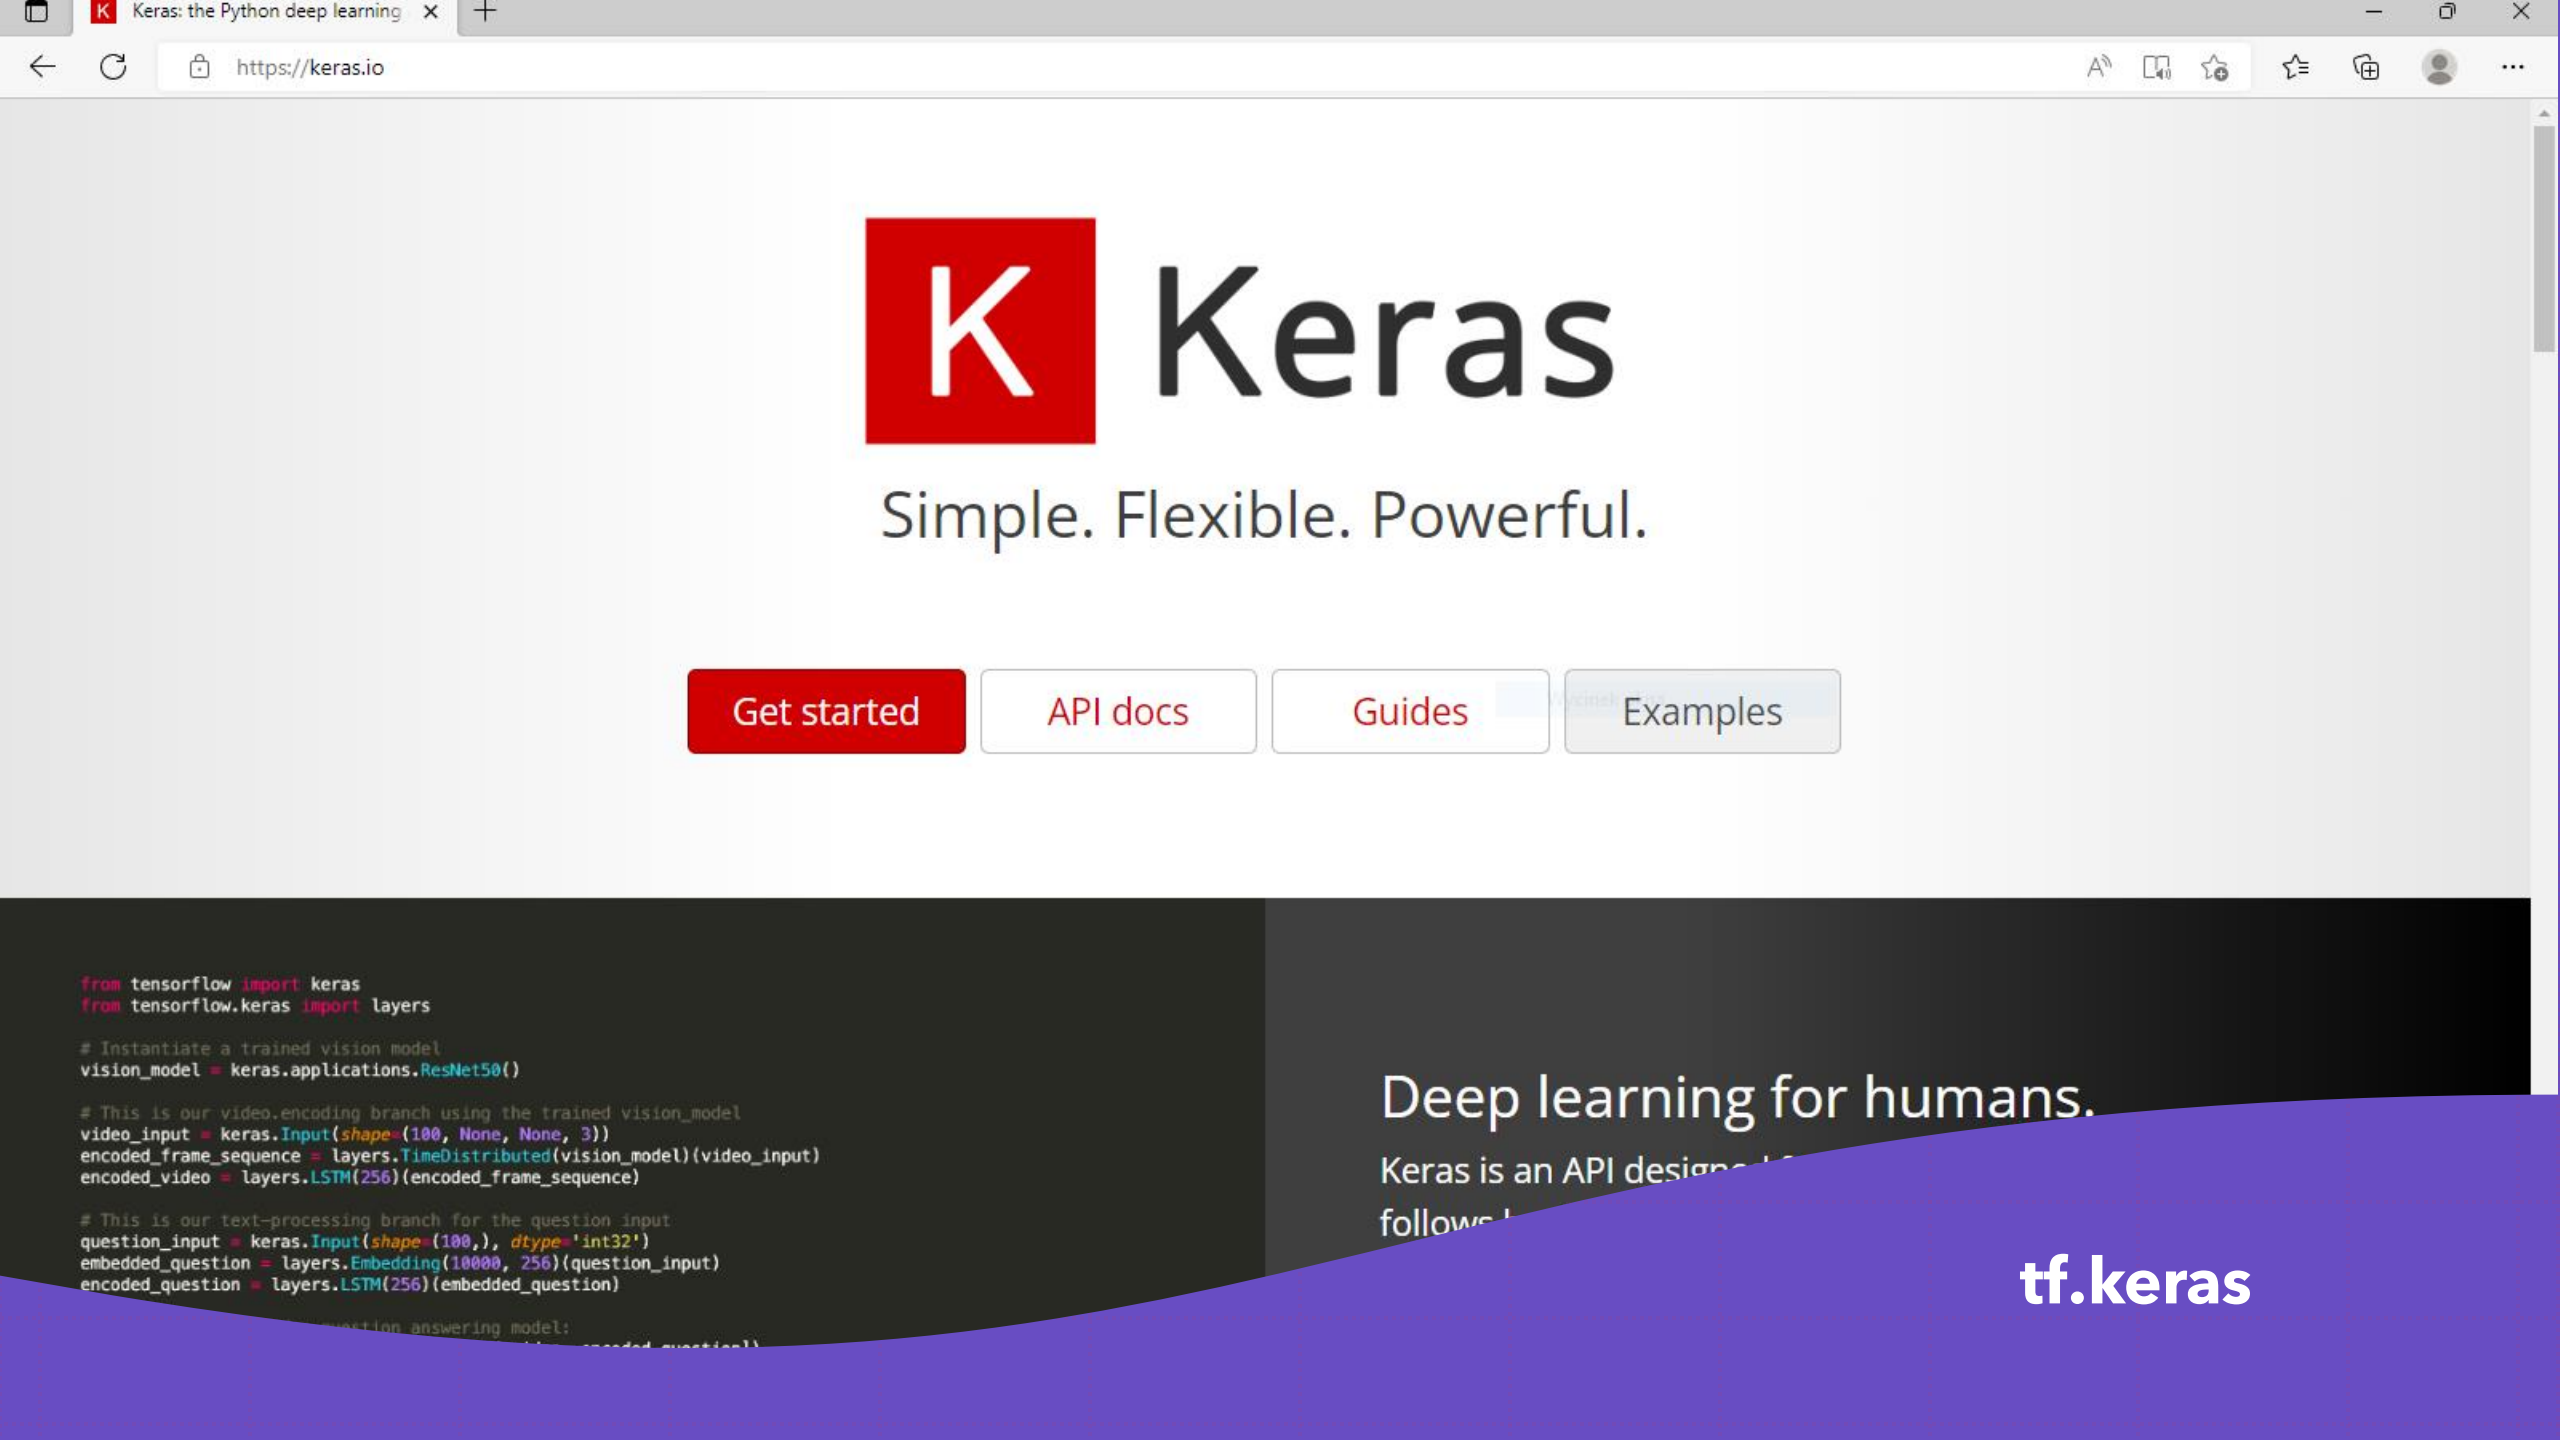
Keras: the Python deep learning
https://keras.io
Keras
Simple. Flexible. Powerful.
Get started
API docs
Guides
Examples
from tensorflow import keras
from tensorflow.keras import layers
# Instantiate a trained vision model
vision_model = keras.applications.ResNet50()
# This is our video encoding branch using the trained vision_model
video_input = keras.Input(shape=(100, None, None, 3))
encoded_frame_sequence = layers.TimeDistributed(vision_model)(video_input)
encoded_video = layers.LSTM(256)(encoded_frame_sequence)
# This is our text-processing branch for the question input
question_input = keras.Input(shape=(100,), dtype='int32')
embedded_question = layers.Embedding(10000, 256)(question_input)
encoded_question = layers.LSTM(256)(embedded_question)
Deep learning for humans.
Keras is an API
follows
tf.keras

Tworzenie modeli w tf.keras

W tf.keras istnieją dwie podstawowe metody tworzenia modeli sztucznych sieci neuronowych:

- Model sekwencyjny
- Funkcjonalne API

Tworzenie modeli w tf.keras

Model sekwencyjny

```
# 3 warstwy
layer1 = layers.Dense(2, activation="relu", name="layer1")
layer2 = layers.Dense(3, activation="relu", name="layer2")
layer3 = layers.Dense(4, name="layer3")

# Wywołanie poszczególnych warstw na danych wejściowych x
x = tf.ones((3, 3))
y = layer3(layer2(layer1(x)))
```

Tworzenie modeli w tf.keras

Funkcjonalne API

```
# 3-wartwowy model sekwencyjny
model = keras.Sequential(
    [
        layers.Dense(2, activation="relu", name="layer1"),
        layers.Dense(3, activation="relu", name="layer2"),
        layers.Dense(4, name="layer3"),
    ]
)
# Wywołanie modelu na danych wejściowych x
x = tf.ones((3, 3))
y = model(x)
```

Dodatki


scikit
learn
VS

Scikit-learn vs TensorFlow

Podobieństwa

Otwarte biblioteki pythonowe udostępniające zestaw narzędzi do uczenia maszynowego.

Scikit-learn vs TensorFlow

Różnice

Scikit-learn biblioteka do uczenia maszynowego ogólnego zastosowania.

TensorFlow biblioteka do uczenia maszynowego wyposażona w wyspecjalizowane narzędzia do tworzeniu sztucznych sieci neuronowych oraz algorytmów uczenia głębokiego.


EAGER
EXECUTION
VS
GRAPH
EXECUTION

Grafy obliczeniowe

TensorFlow daje użytkownikowi możliwość wyboru jednego z dwóch trybów wykonywania kodu:

- eager execution (linijka po linijce)

- graph execution (kod wykonywany na podstawie tzw. grafu obliczeniowego)

W starszej wersji biblioteki dostępny był tylko tryb trudniejszy – graph execution (wzorzec lazy evaluation), co miało duży wpływ na spadek popularności biblioteki. Pisanie kodu w starszych wersjach biblioteki polegało na ręcznym tworzeniu tzw. **grafu obliczeniowego**, w którym wierzchołkami były tensory, a krawędziami operacje wykonywane na tych tensorach. Wykonanie kodu polegało na uruchomieniu stworzonego grafu w ramach tzw. **sesji**. W wersji TF2.0 twórcy ustawili tryb eager execution jako domyślny i obecnie można pisać w tensorflow programy nie zdając sobie nawet sprawy, że taki graf obliczeniowy kiedyś był niezbędny. Eager execution wykonuje kod natychmiast, instrukcja po instrukcji, co jest bardzo wygodne, ale w przypadku bardziej złożonych modeli może być wolniejsze (graf obliczeniowy pozwala na optymalizację obliczeniową algorytmu poprzez realizację kosztownych operacji tensorowych za pomocą szybszych operacji na grafach za pomocą obiektu **Grappler**).

Grafy obliczeniowe – dekorator tf.function

Ze względu na możliwości optymalizacyjne jakie dają grafy obliczeniowe twórcy tensorflow nie wyrzucili grafów w nowszych wersjach. Eager execution pomija grafy obliczeniowe wykonując kod linijka po linijce. Wciąż można jednak w nowszych wersjach wykonać napisany kod na grafie. Nie jest to już jednak tak żmudne jak było w starszych wersjach, w których cały graf trzeba było stworzyć ręcznie. W tensorflow 2.x do budowania grafu służy dekorator tf.function. Udekorowanie funkcji dekoratorem tf.function powoduje, że tensorflow traktuje ją jako pojedynczy obiekt grafu.

Przykładowy kod można znaleźć w notatniku w sekcji Dodatki.

Obrazy w uczeniu maszynowym

Struktura czarno-białego (binarnego) obrazu

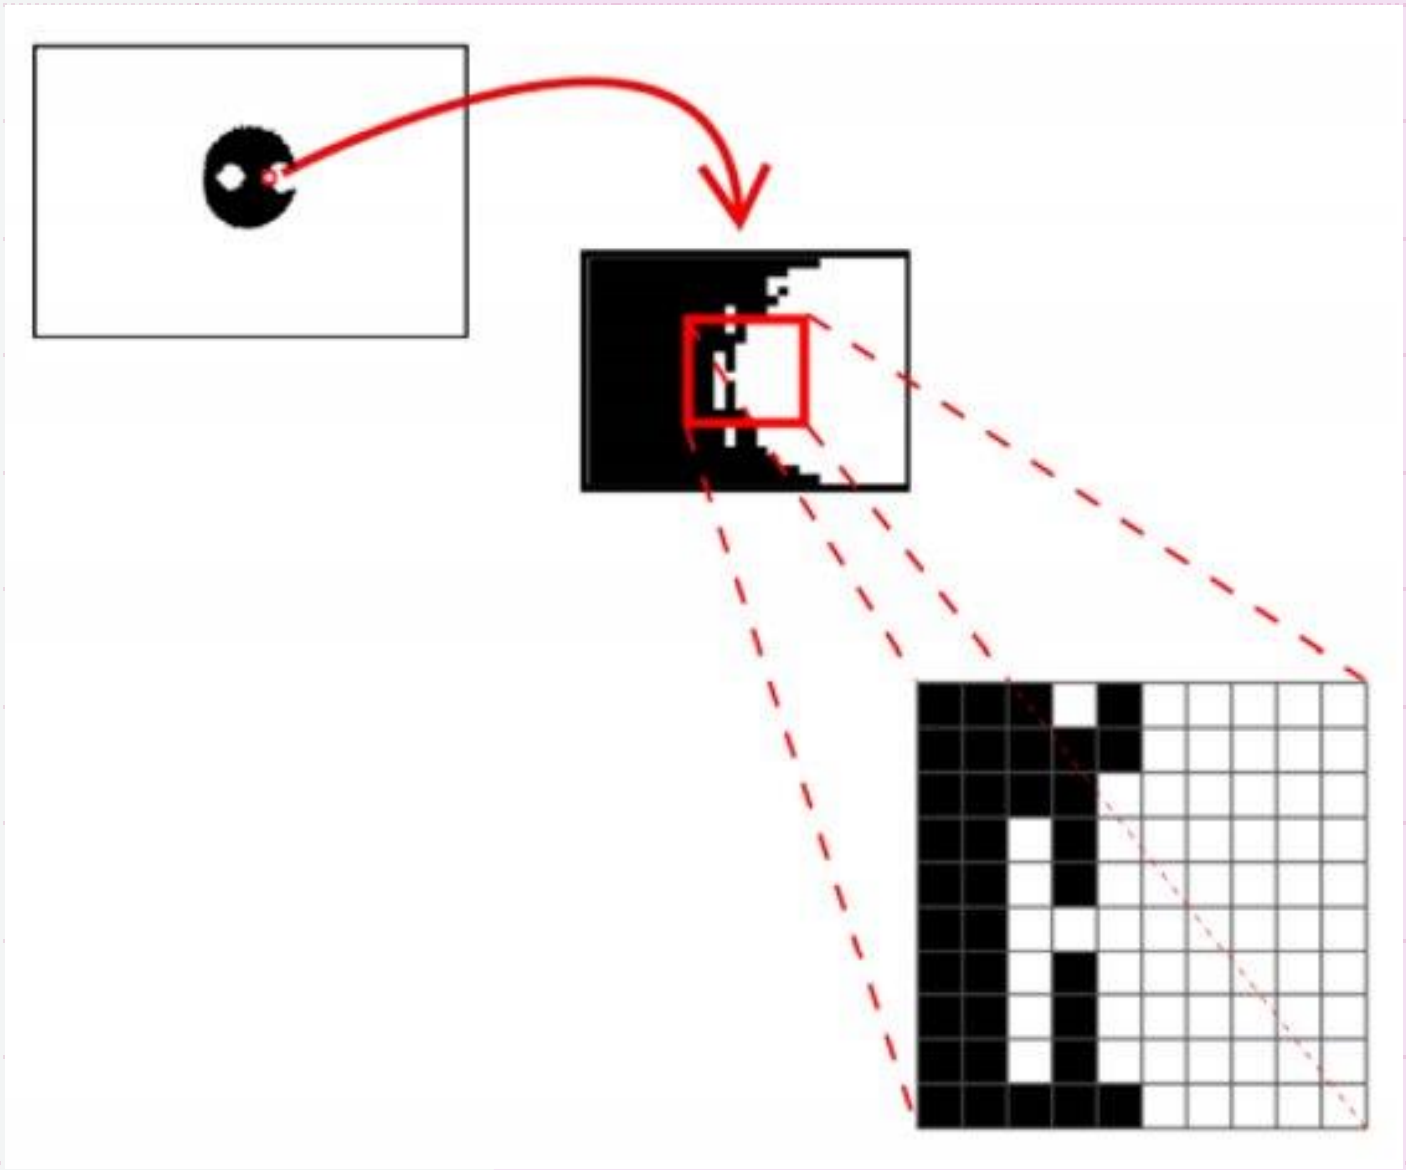

Macierzowa reprezentacja obrazu

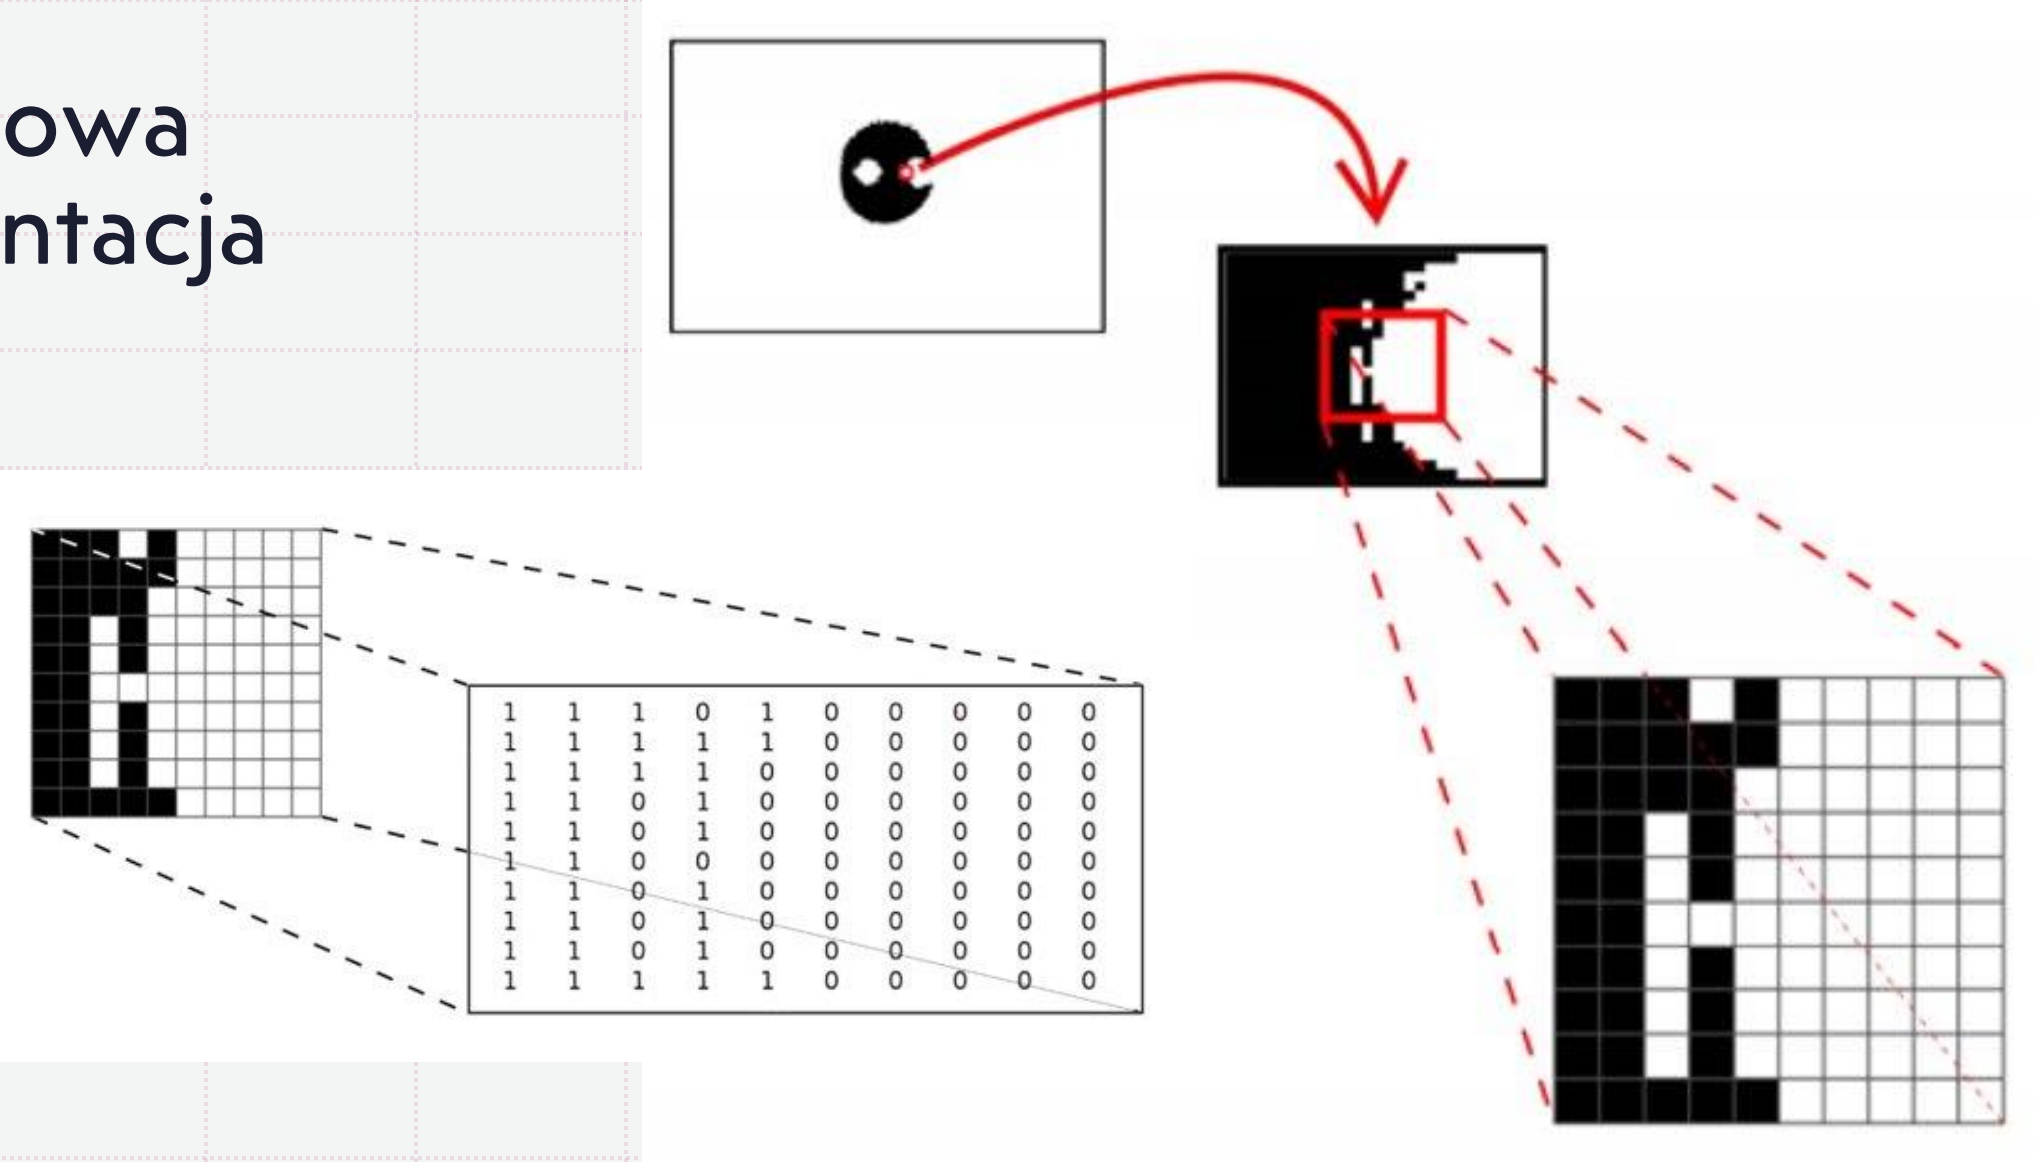

Funkcyjna reprezentacja obrazu

W ujęciu algebraicznym macierz może reprezentować odwzorowanie (funkcję). Tym samym o obrazie możemy myśleć jako o funkcji (odwzorowaniu).

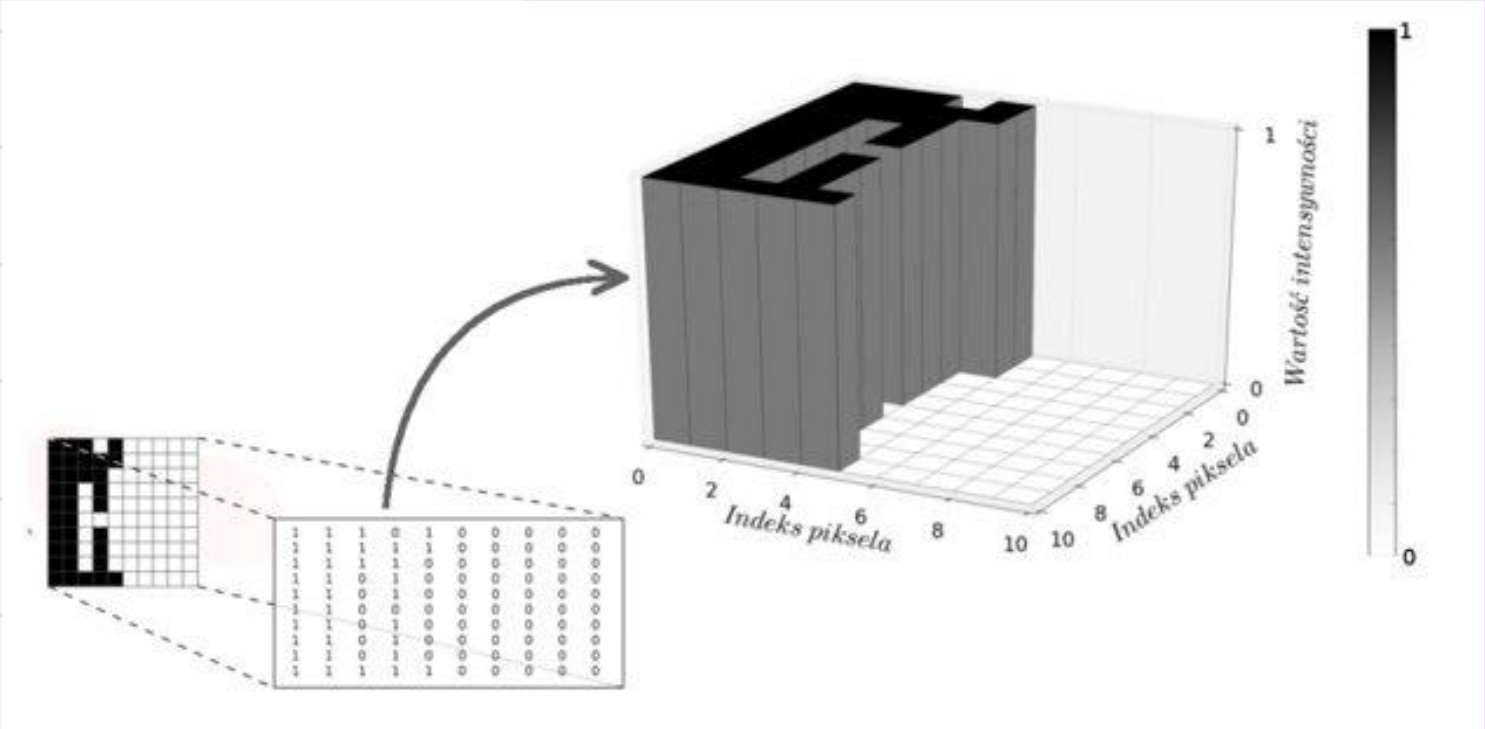

Uogólnienie obrazu na skalę szarości (reprezentacja macierzowa)

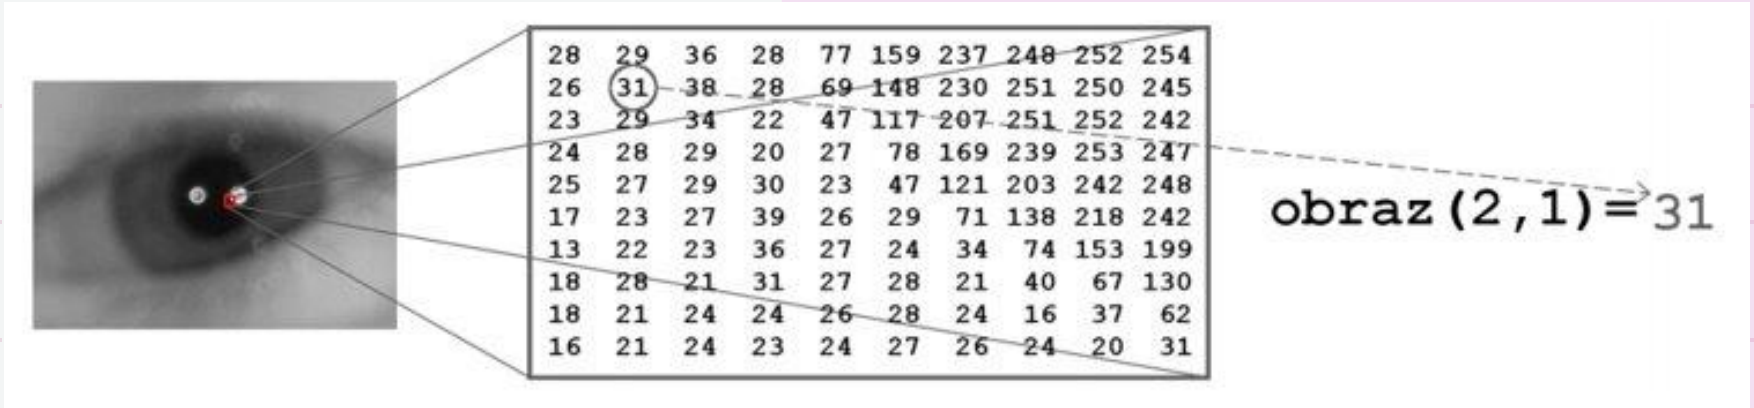

Uogólnienie obrazu na skalę szarości (reprezentacja funkcyjna)

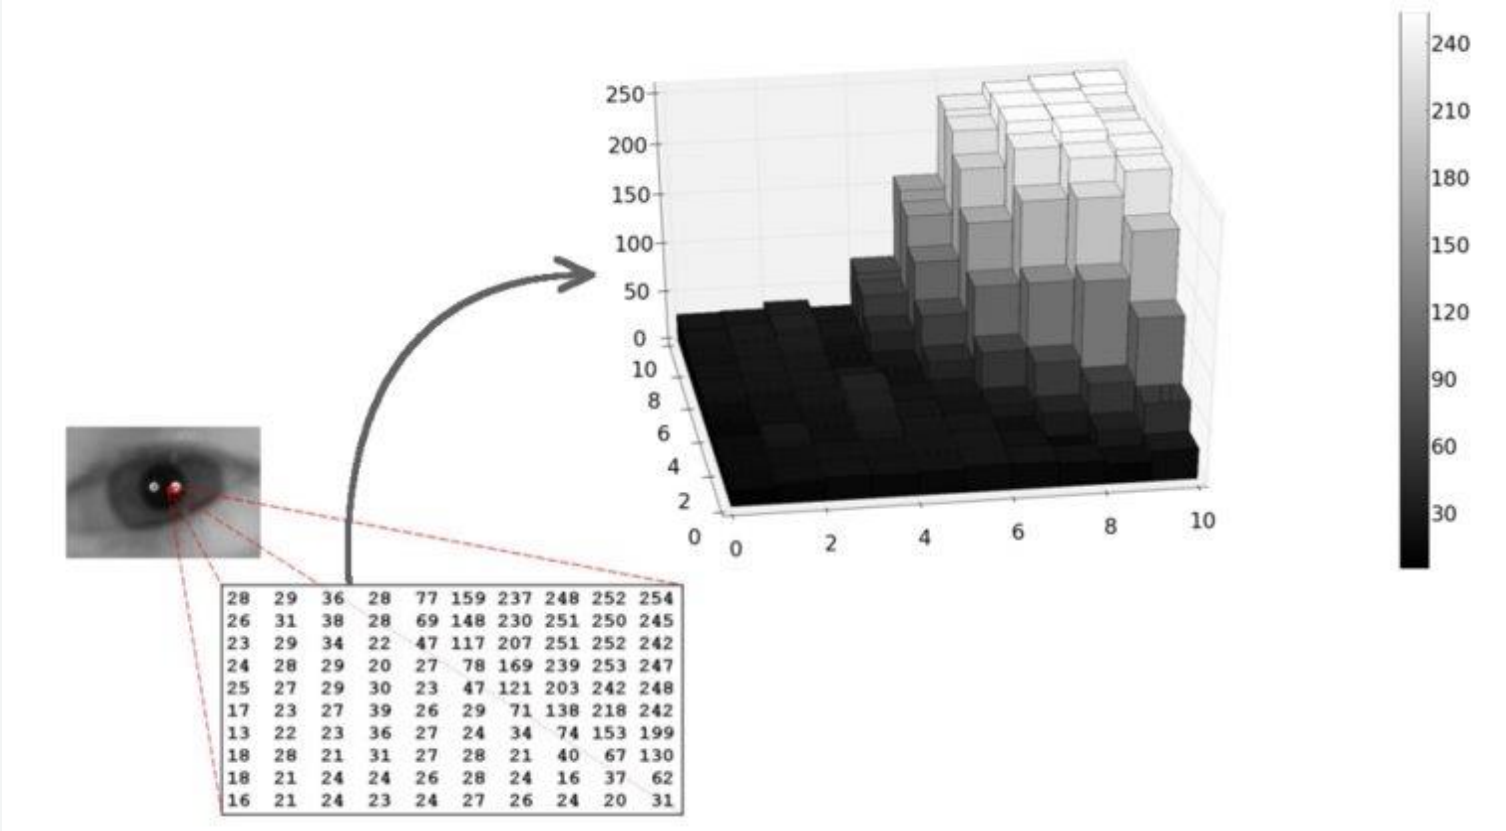

Uogólnienie obrazu na kolor (reprezentacja macierzowa)

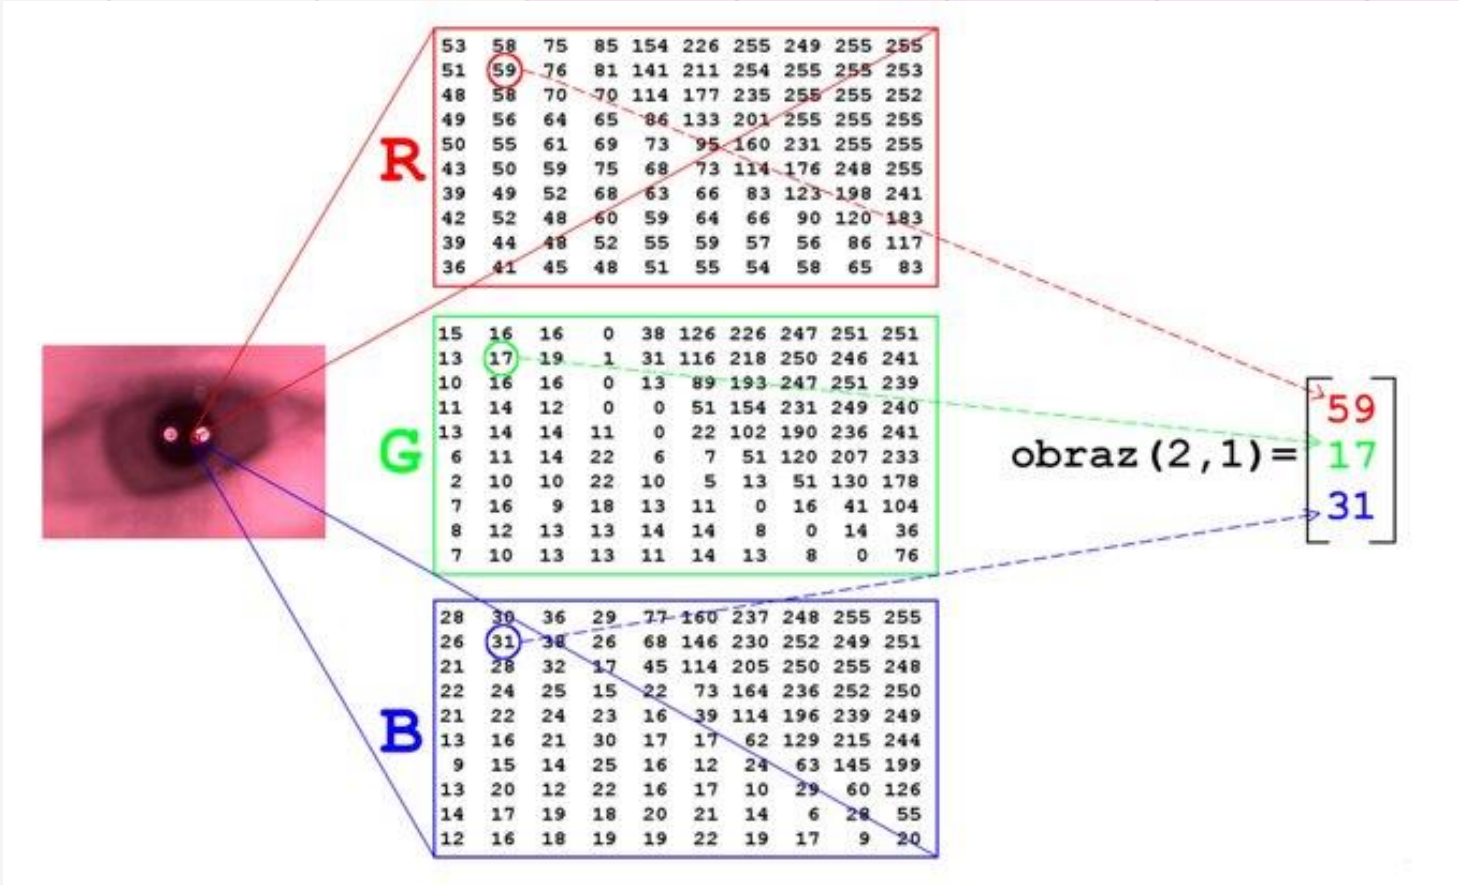

Loss functions

Popularne funkcje kosztów dla regresji liniowej

MSE $$L(a) = a^2$$

MAE $$L(a) = |a|$$

Huber $$L_\delta(a) = \begin{cases} \frac{1}{2}a^2 & \text{for } |a| \le \delta, \\ \delta \cdot \left(|a| - \frac{1}{2}\delta\right), & \text{otherwise.} \end{cases}$$

Popularne funkcje kosztów dla regresji liniowej

1. **Średni błąd kwadratowy** (*ang. mean square error, mse*)
   - mocno każe outlier-y
   - duża czułość w pobliżu minimum

2. **Średni błąd absolutny** (*ang. mean absoulte error, mae*)
   - liniowy względem wartości błędu
   - mała czułość w pobliżu minimum

3. **Błąd Hubera** (*ang. Huber error*)
   - zachowuje się podobnie do mse w pobliżu minimum (zwiększenie czułości w pobliżu min)
   - zachowuje się podobnie do mae z dala od minimum (zmniejszenie wpływu outlier-ów)